MVTec AD Anomaly Detection

산업경영공학과 12210588 고우현

인하대학교
INHA UNIVERSITY

Operations Research and
Artificial Intelligence Lab

Contents

Operations Research and Artificial Intelligence Lab

- Anomaly Detection
- Dataset
- Structure
- Bottle Class
- Grid Class
- Conclusions

Anomaly Detection

- 정상 이미지와 비교하여 결함 여부를 판별

- 이미지에서 여러 개의 객체를 찾아내고, 무엇인지 분류하는 객체 탐지는 일반 이미지를 입력 받아 Bounding Box와 Class Label을 출력하는 반면 불량 탐지는 제품 이미지를 입력 받아 이상 여부 (정상 또는 불량인 binary), 이상 점수, Anomaly Map (결함 위치를 보여주는 히트맵) 등을 출력

- 결함의 위치와 모양은 다양하지만, 대부분 결함은 드물고 작은 영역으로 대부분 정상 이미지만 학습

- 위치와 모양이 불규칙하여 Bounding Box 대신 Anomaly Map 출력

Dataset

- MVTec AD : 산업용 결함 탐지 연구를 위해 만들어진 산업용 이미지 기반 anomaly detection 데이터셋
- 총 15개의 제품 클래스 (e.g. bottle, capsule, screw, grid, wood, etc.)
- 각 클래스 별 정상 이미지와 결함 이미지
- 스크래치, 균열, 오염, 찍힘, 누락 등 다양한 산업용 결함 유형
- Bottle, Grid 클래스를 사용해서 진행

Structure

- Data → Model → Feature → Memory Bank → Anomaly Score → 시각화 순서로 진행
- PatchCore : 산업용 anomaly detection에서 성능이 좋은 one-class(정상 이미지만 학습), feature-based anomaly detection 모델
- Pre-trained CNN Backbone : ResNet18, ResNet34 등 이미지 특징을 잘 뽑는 모델을 사용, 특정 layer의 feature map을 사용
- Patch 단위 feature 추출 :이미지를 작은 patch 단위로 나누고 각 패치의 feature 추출
- Memory Bank 구축 :정상 이미지 feature만 저장한 후 NearestNeighbor 모델 사용, 테스트 이미지의 각 patch feature와 memory bank를 비교
- Anomaly Score 계산 : 각 patch feature와 memory bank 간의 거리를 계산하는 anomaly score로 patch가 정상과 얼마나 다른지를 표현, 이를 통해 pixel-level anomaly map 생성 가능

Bottle Class – Basic Results

Operations Research and Artificial Intelligence Lab

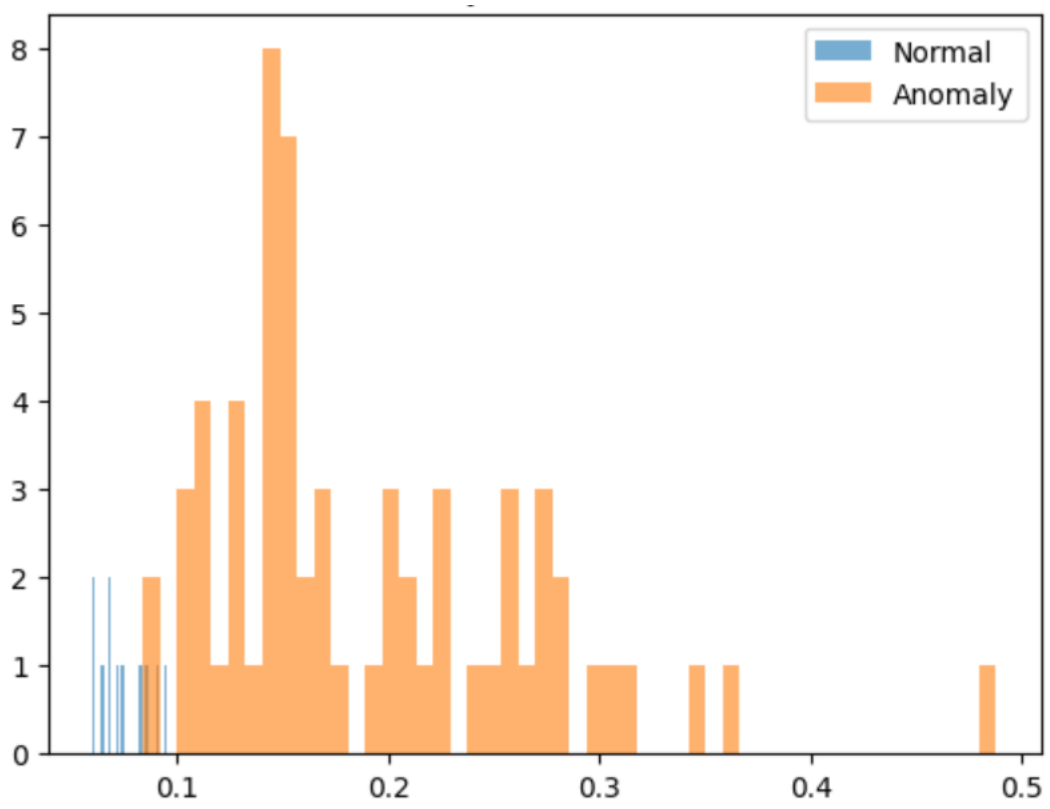

- Backbone으로 ResNet18 사용, layer 3에서 feature 추출
- x축 : PatchCore에서 계산한 anomaly score, y축: 각 점수 구간에 속하는 이미지 개수
- 정상과 이상 데이터 간의 분포가 거의 겹치지 않고 분리됨
- 정상 데이터 분포는 대부분 0.05 ~ 0.08 구간에 매우 좁게 형성
- 이상 데이터 분포는 0.1 ~ 0.5 사이의 넓은 구간에 분포하며, 0.15 부근에서 가장 높은 빈도

→ 이를 통해 모델이 학습한 정상 패턴에 대한 확신도가 매우 높고, 다양한 형태의 결함이 특징으로 추출되고 있음

Bottle Class – Layer-wise Comparison

Operations Research and Artificial Intelligence Lab

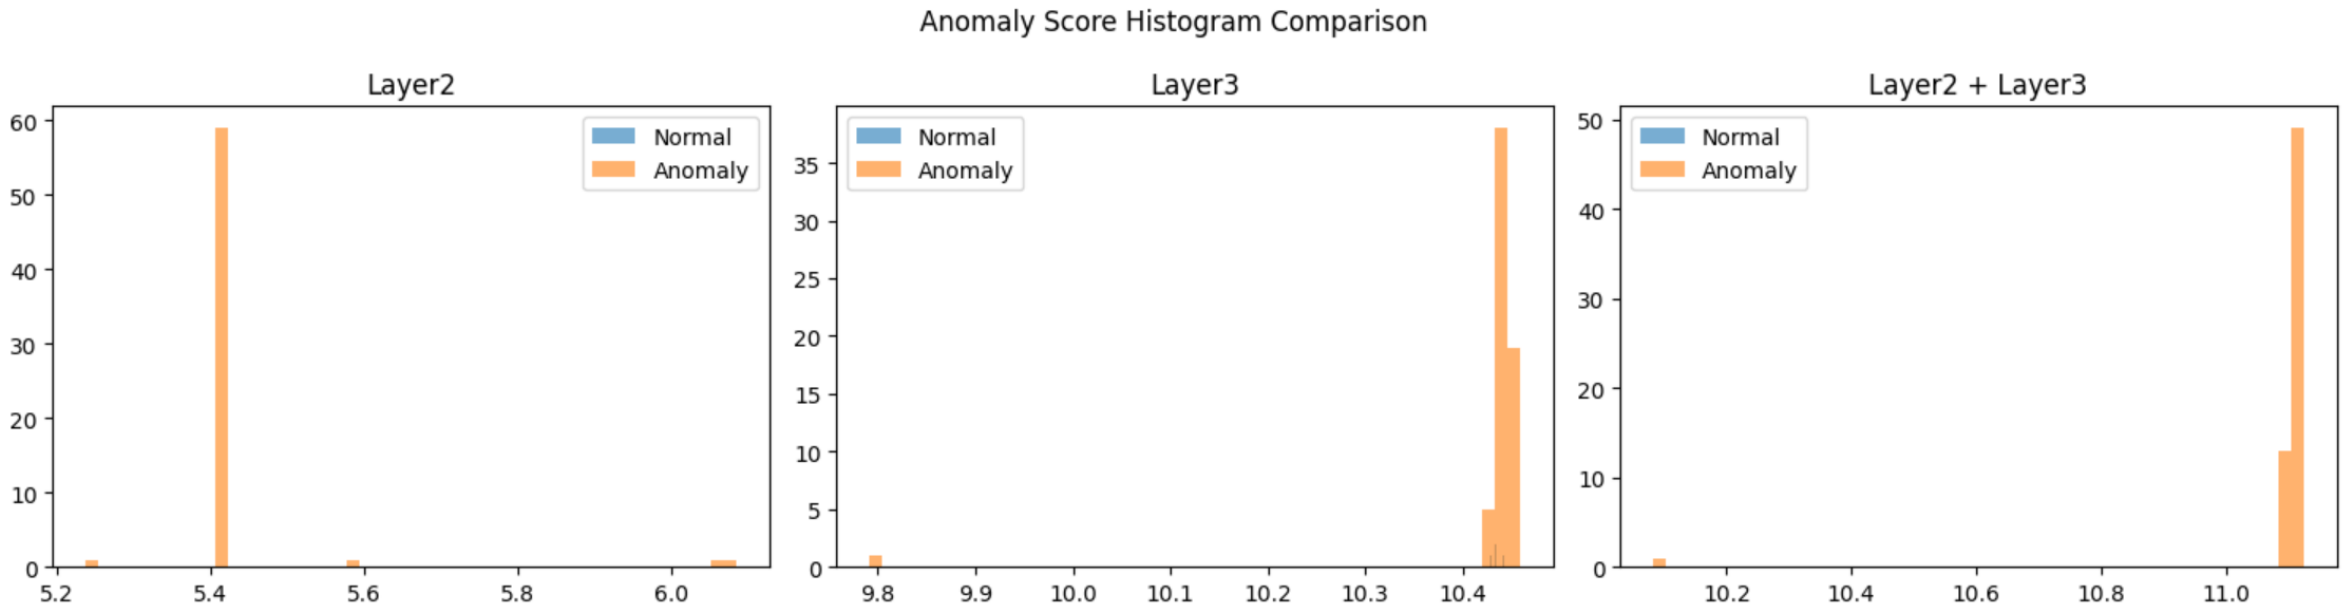

- Layer 2 : 점수대가 약 5.2 ~ 6.2 사이에 형성되어 정상과 불량의 구분이 가능하나 점수의 절대적인 수치가 낮고 분포가 단순함
- Layer 3 : 점수대가 약 9.8 ~ 10.5 사이로 이상치를 더 민감하게 잡아냄
- Layer 2 + Layer 3 : 점수대가 11.0 이상으로 두 layer를 합쳤을 때 이상치에 대한 확신이 가장 강력해짐

→ Layer 3에서 일부 정상 데이터가 검출되는데 이는 Layer 3이 Layer 2보다 더 고차원적인 특징을 추출해 정상 데이터의 일부가 이상치 점수와 근접해지는 경향이 있음 이런 한계를 Layer 2와 Layer 3을 결합해 하위 layer의 세부 정보를 결합

Bottle Class – Layer-wise Comparison

Operations Research and Artificial Intelligence Lab

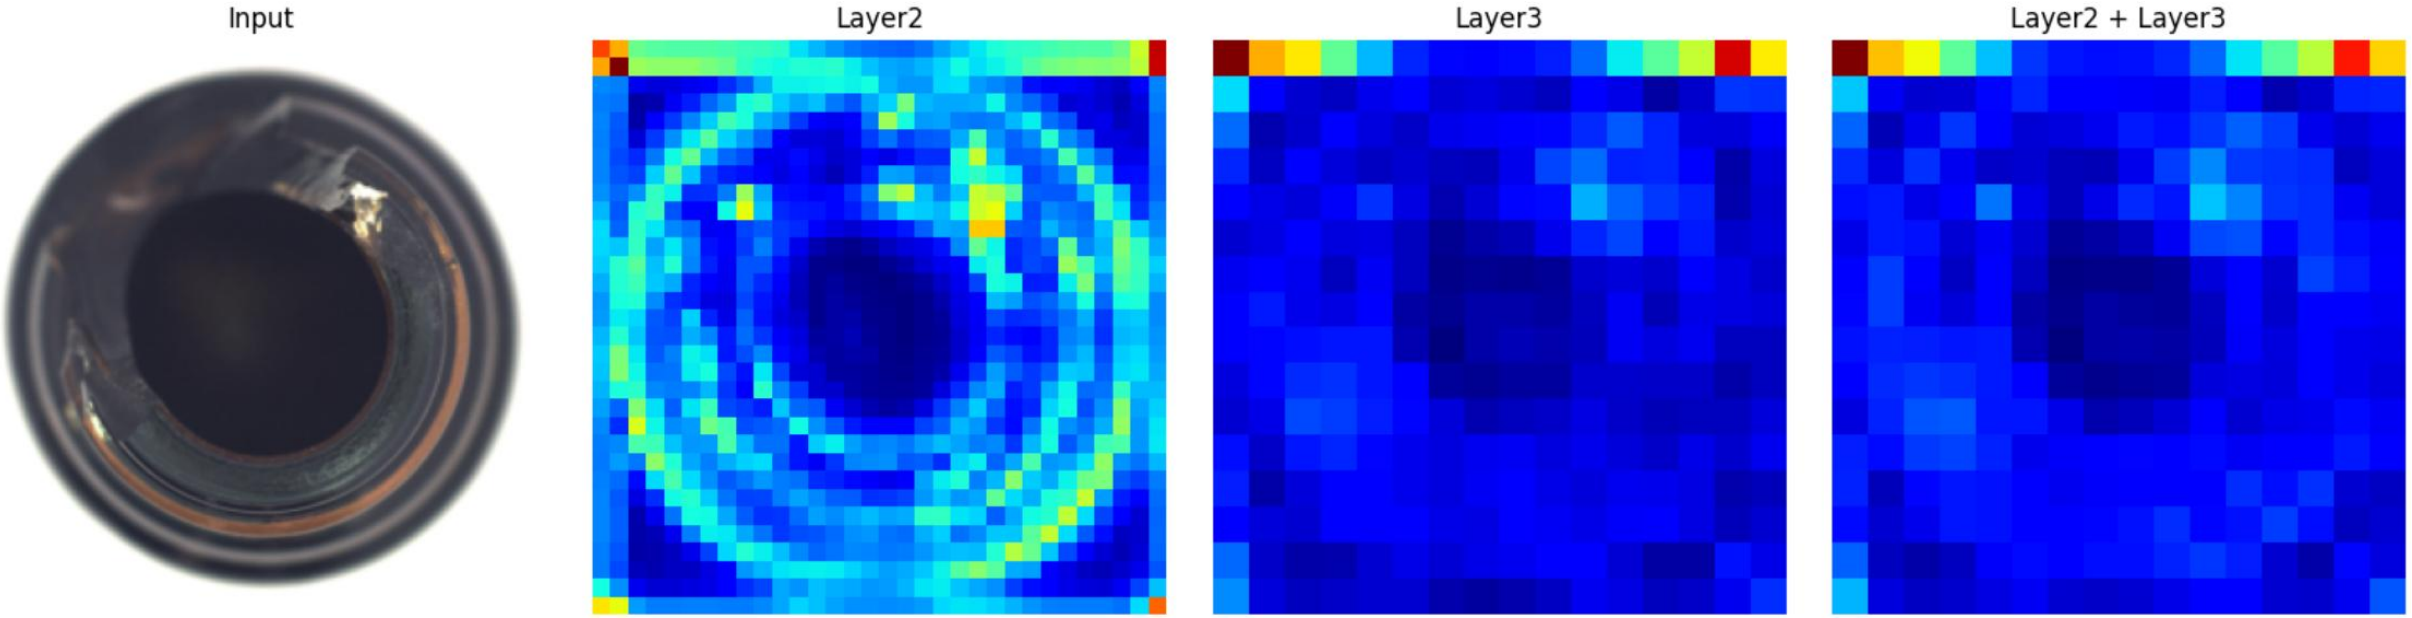

- Input : 실제 불량 이미지
- Layer 2 : 세밀한 에지 정보를 반영해 깨진 부위 뿐만 아니라 병의 둥근 테두리 전체에 높은 활성화
- Layer 3 : 병의 테두리보다 실제 깨진 결함 부위 주변을 더 넓게 포착
- Layer 2 + Layer 3 : 국소적인 정밀도와 전역적인 문맥이 합쳐져 배경 노이즈는 억제되고, 실제 결함 부위에만 강하게 활성화

→ Layer 2 + Layer 3은 단일 layer의 특징을 모두 활용하여 작은 결함과 구조적 이상을 모두 탐지가 가능해 일반적으로 가장 성능이 좋음

Bottle Class – Backbone Comparison

Operations Research and Artificial Intelligence Lab

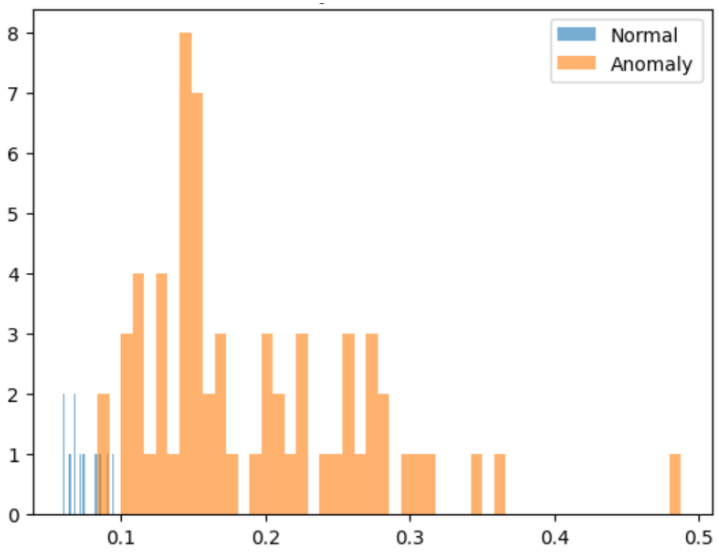

Anomaly Score Distribution (ResNet34, layer3)

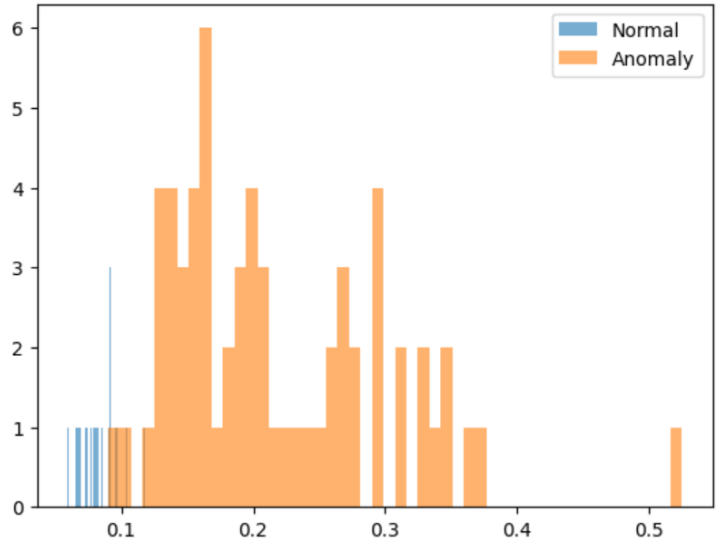

- 각 ResNet18과 ResNet34 모델을 적용하고 Layer 3에서 추출한 히스토그램
- ResNet18 : 정상군이 0.05 ~ 0.08 사이의 아주 좁은 구간에 데이터 밀집, 불량군이 약 0.10 ~ 0.49 사이 분포, 정상군과 불량군의 간격이 더 넓고 뚜렷함
- ResNet34 : 정상군이 0.05 ~ 0.09 사이로 상대적으로 분포가 더 넓게 퍼져있음, 불량군이 약 0.12 ~ 0.52 사이 분포, 정상군과 불량군의 간격이 미세하게 좁아짐
- Bottle 클래스는 기하학적 구조가 단순해 ResNet18 정도의 깊이만으로 충분히 특징을 추출할 수 있어 더 가벼운 모델인 ResNet18이 정상 데이터를 훨씬 더 일관되게 파악
- 모델이 깊어질수록 특징이 더 추상화되고 민감해져 불량 점수의 최댓값이 ResNet18보다 ResNet34에서 더 높게 나타남, 이는 확실한 불량에 대해 더 높은 점수를 부여하지만 정상 데이터의 점수도 같이 밀어올리는 부작용 발생

Bottle Class – Comprehensive Comparison

Operations Research and Artificial Intelligence Lab

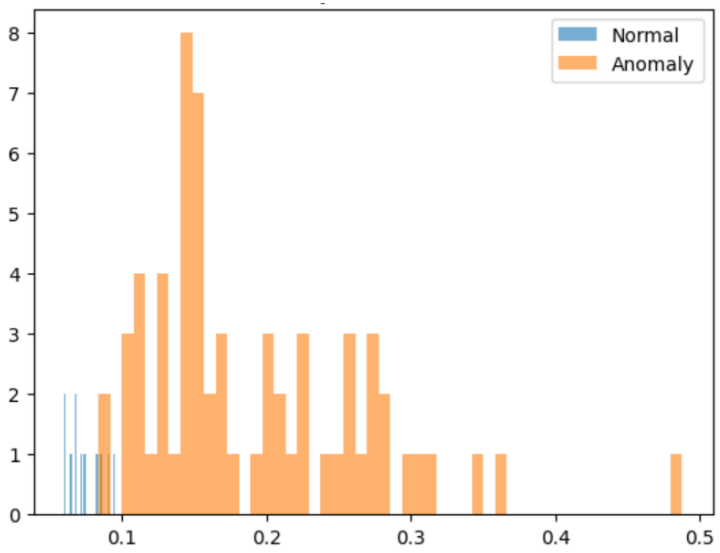

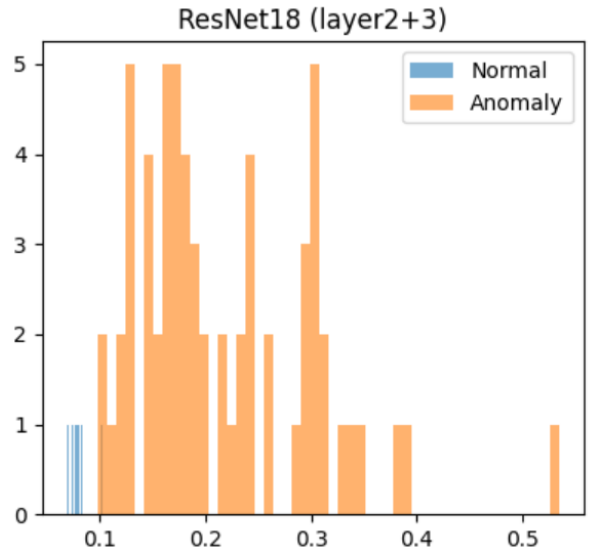

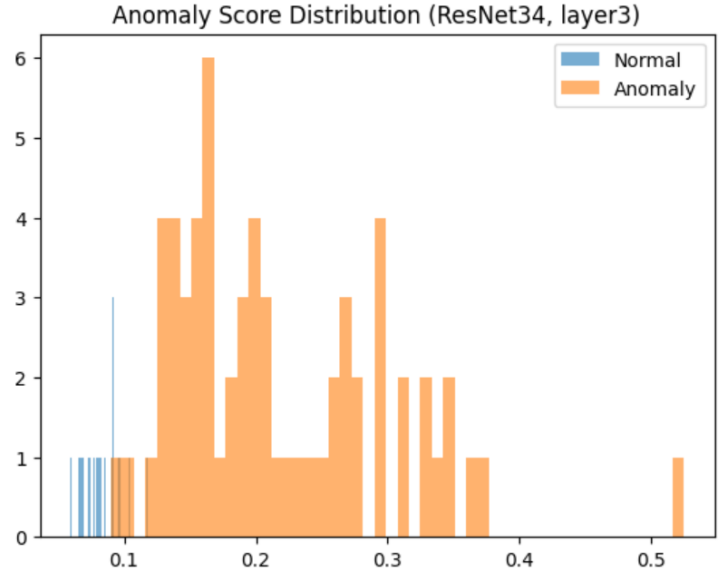

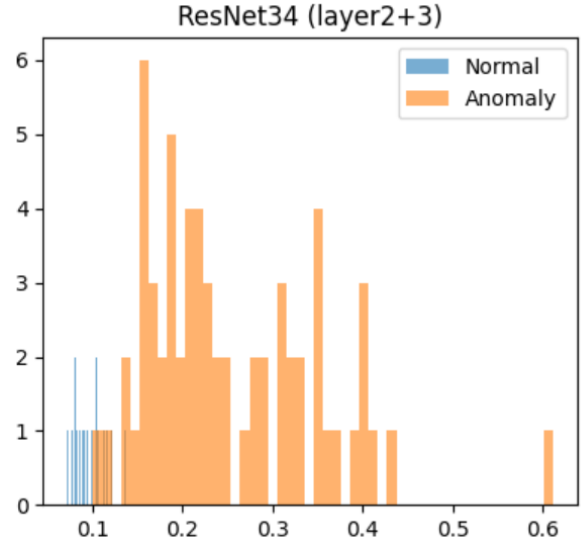

- Backbone별 (ResNet18, ResNet34), Layer별 (Layer 2, Layer 2+ Layer 3) 히스토그램 비교
- 어떤 Backbone을 쓰더라도 Layer 2 단독으로 사용하기보다 Layer 2 + Layer 3 결합 시 이상치의 점수의 범위가 넓어지고 분리도가 향상
- Layer 2 + Layer 3 결합 상태에서 ResNet34가 ResNet18보다 이상치 점수를 더 높게 부여

→ ResNet18은 정상 데이터가 가장 좁은 범위에 모이는 경향이 있어 매우 안정적, ResNet34는 정상 분포가 상대적으로 넓어지지만 이상치와의 거리 자체가 훨씬 멀기 때문에 실질적인 탐지 성능이 더 우수

Grid Class – Basic Results

Operations Research and Artificial Intelligence Lab

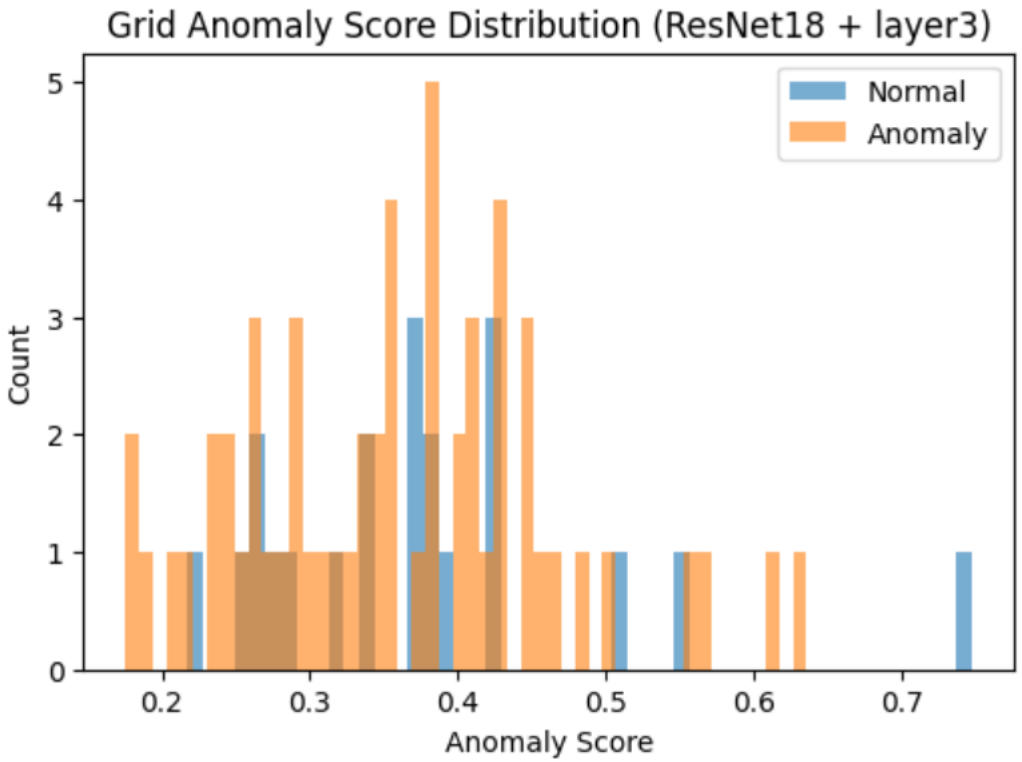

- Grid 클래스를 ResNet18를 Backbone으로 하고 Layer 3에서 특징을 추출
- 히스토그램에서 정상과 불량의 경계를 가를 수 있는 빈 공간이 없음
- 정상 데이터 중 하나가 0.7이 넘는 높은 점수를 기록해 모서리 노이즈나 촬영 환경의 미세한 변화가 Layer 3에서 과하게 반영되어 모델이 이를 이상한 것으로 오판
- Layer 3의 추상화된 특징만으로는 Grid 클래스의 결함인 미세한 격자의 휨이나 간격 차이와 정상적인 격자의 미세한 변동을 구분하지 못함
- 기하학적 구조가 단순한 Bottle 클래스에서는 Layer 3 단독으로는 분리가 가능했지만 기하학적 구조가 상대적으로 복잡한 Grid 클래스에서는 탐지에 실패

→ 기하학적 구조가 복잡할수록 단일 스케일의 특징보다는 여러 layer의 특징 결합이 필수

Grid Class – Layer-wise Comparison

Operations Research and Artificial Intelligence Lab

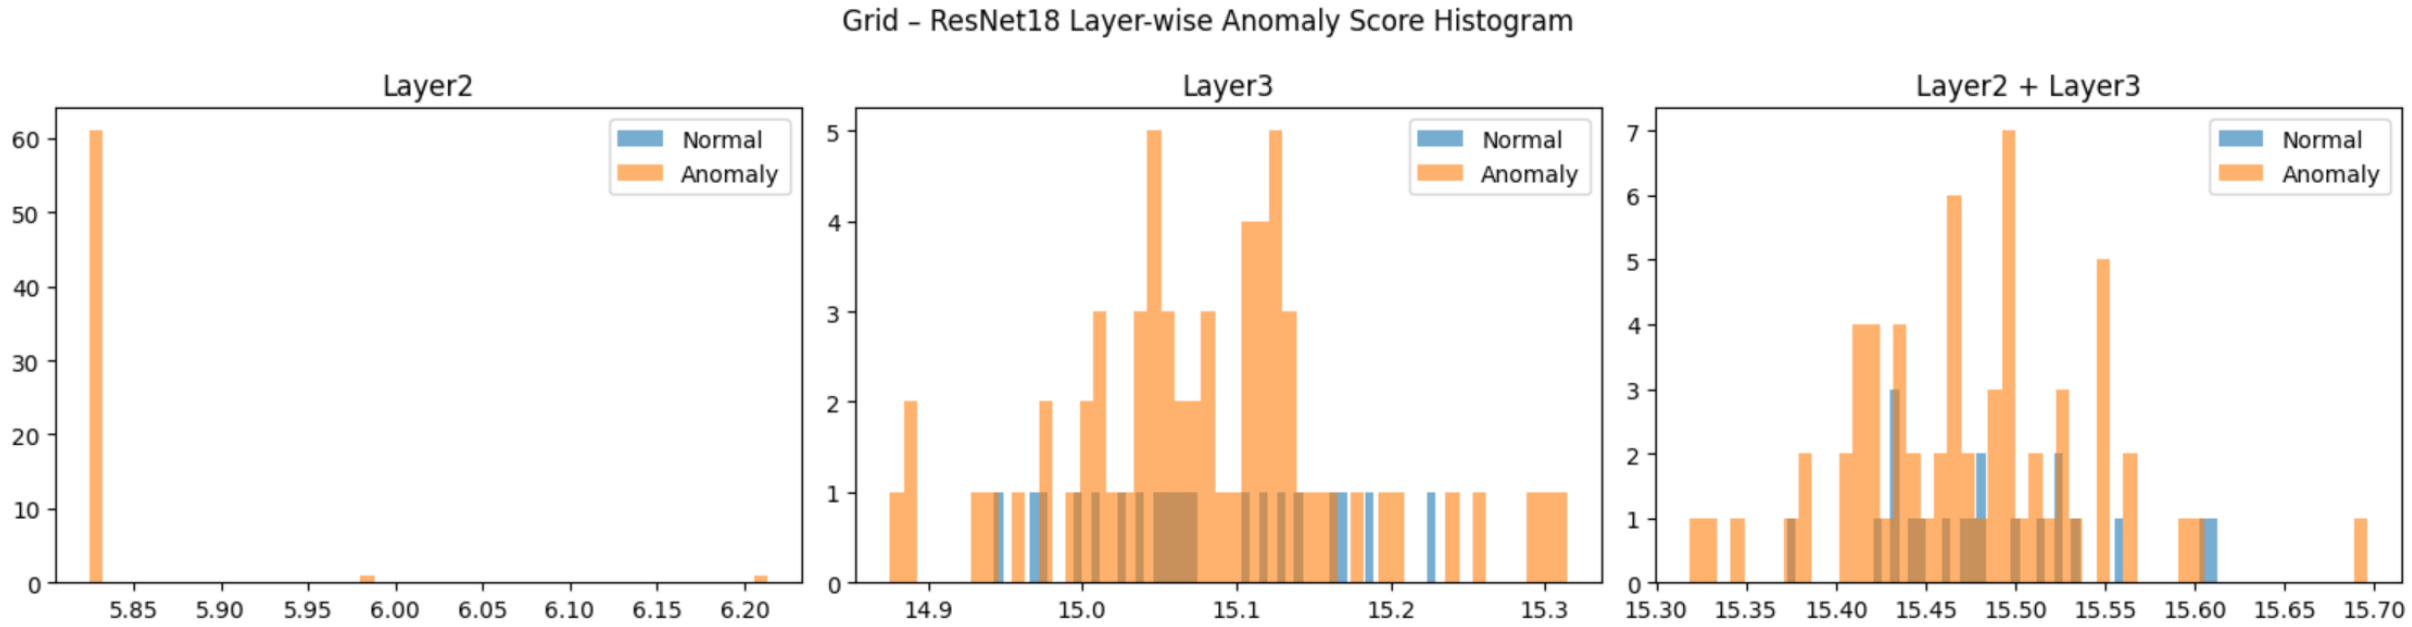

- Layer 2 : 이상 점수 범위가 약 5.8 ~ 6.2의 낮은 수치로 정상과 불량이 완전히 겹쳐 구분되지 않음
- Layer 3 : 이상 점수 범위가 약 14.8 ~ 15.3 사이로 분포가 뒤섞여 있어 오탐지나 미검출의 발생 가능성이 매우 높음
- Layer 2+ Layer 3 : 이상 점수 범위가 약 15.3 ~ 15.7 사이고 정상과 불량의 경계가 형성되기 시작

→ Layer 2에서는 정상과 불량을 전혀 구분하지 못하고 Layer 3에서는 정상 범주의 미세한 변동과 실제 결함을 분리할 만큼의 충분한 해상도가 없으므로 다양한 수준의 특징을 통합하는 과정이 필수

Grid Class – Layer-wise Comparison

Operations Research and Artificial Intelligence Lab

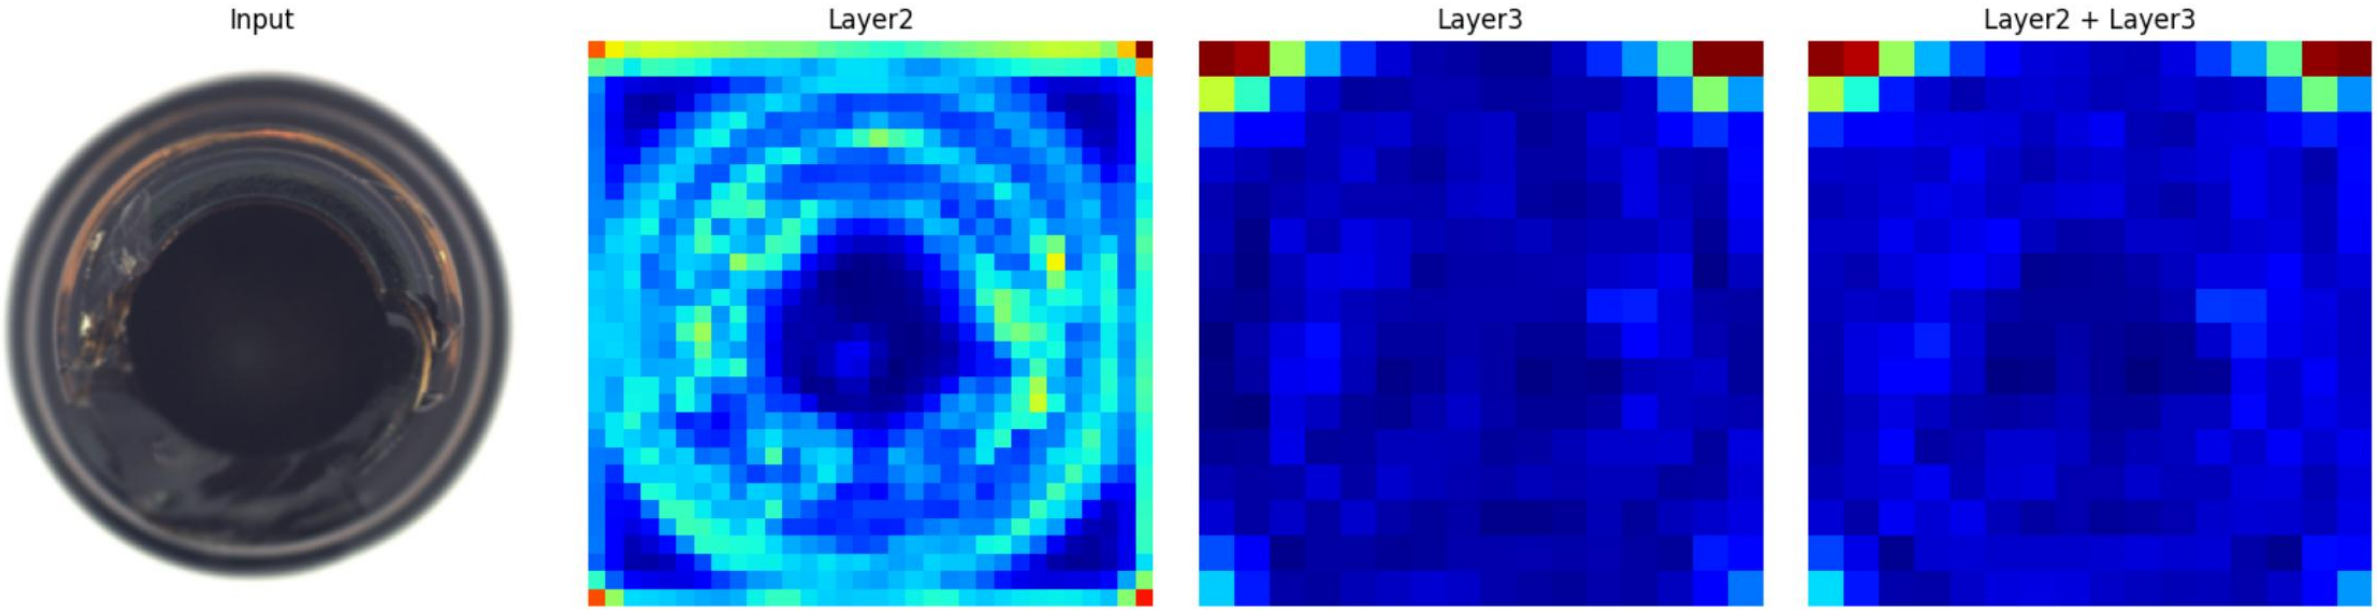

- Layer 2 : 격자 무늬 전체에 하늘색 노이즈가 강하게 발생해 국소적 질감에만 민감하여 정상과 결함을 구분하지 못함
- Layer 3 : 전체적으로 어두운 파란색이며 결함 부위의 활성화가 매우 희미, 결함의 미세한 특징을 잡아낼 해상도가 부족
- Layer 2 + Layer 3 : 배경 노이즈가 억제되고 실제 결함 위치에만 활성화 집중, 구조적 정보와 세부 질감이 결합되어 최적의 탐지 성능
- 단일 layer로는 시각적 노이즈 및 수치적 중첩으로 인해 Grid 탐지에 한계가 있으나 layer 결합을 통해 결함 위치 국소화와 점수 변별력 동시에 확보

Grid Class – Backbone Comparison

Operations Research and Artificial Intelligence Lab

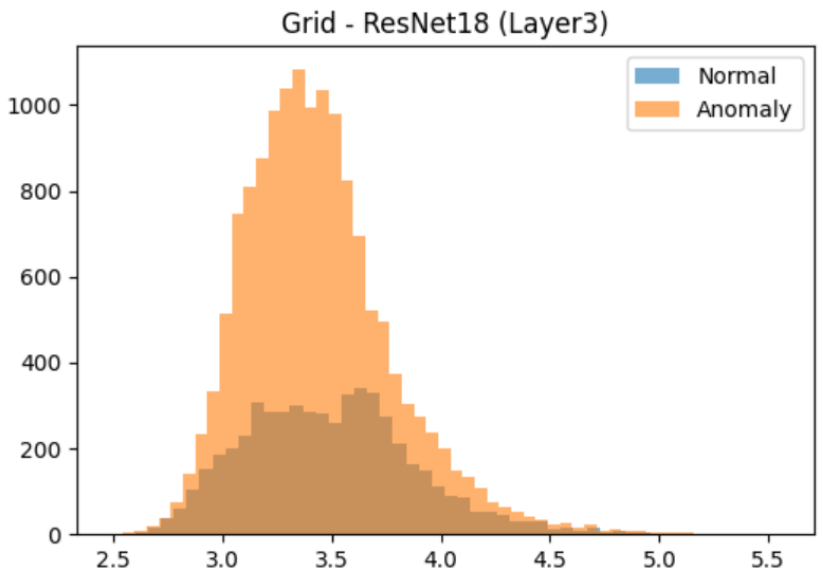

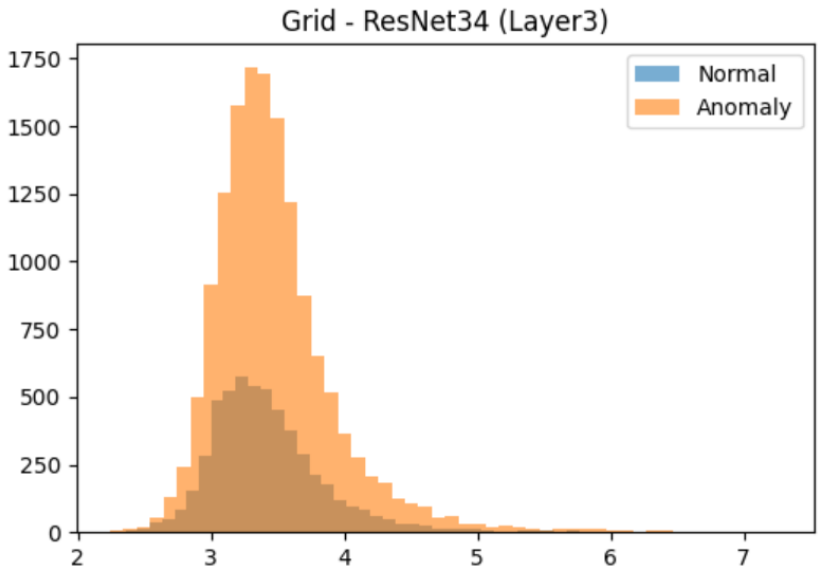

Backbone을 각 ResNet18, ResNet34를 적용하여 Layer 3에서 특징을 추출

ResNet18 : 약 2.5 ~ 5.0 사이의 분포로 정상과 불량의 중첩 정도가 심각

ResNet34 : 약 2.5 ~ 6.5 사이의 분포로 두 분포의 피크 지점이 동일하여 중첩 정도가 매우 심각

ResNet34의 이상치 점수가 7.0 근처까지 확장되어 모델이 깊어질수록 특징을 더 예민하게 추출해 확실한 불량에 대해서는 더 높은 점수 부여

Bottle 클래스에서는 두 분포가 달라진 것과 대조적으로 Grid 클래스에서는 Backbone의 차이가 크지 않고 단일 레이어만으로는 탐지가 불가능

앞의 결과를 통해 Backbone을 ResNet34로 업그레이드해도 성능 개선이 미미하지만, Layer 2 + Layer 3의 결합으로는 성능 개선이 확실하다는 특징

Conclusions

Operations Research and Artificial Intelligence Lab

- Bottle 클래스는 object 중심으로 비교적 큰 결함이 존재해 Layer 3, Layer 2+ Layer 3이 효과적, Grid 클래스는 texture 중심으로 미세 패턴의 결함이 존대해 Layer 2+ Layer 3이 효과적
- 데이터 특성에 따라 layer 선택이 중요
- ResNet18은 겹침이 적고 성능이 충분히 좋고, ResNet34는 anomaly score 분포가 조금 더 넓음
- 따라서 복잡도가 높은 데이터일 때는 깊은 Backbone, 단순 object 중심 데이터에서는 ResNet18도 충분
- PatchCore 기반 feature memory approach는 데이터셋의 정상 패턴 학습에 효과적이며 Backbone과 layer의 선택에 따라 anomaly detection의 성능이 달라짐

Q & A