CNN vs ViT

산업경영공학과 12210588 고우현

인하대학교
INHA UNIVERSITY

Operations Research and
Artificial Intelligence Lab

Contents

- Datasets
- Models
- Experimental Setup
- Comparison & Analysis
- Performance Improvement
- Conclusion

CNN vs ViT

- CNN은 지역적 특징을 학습하고 ViT는 전역적 관계를 모델링한다는 구조적 차이 존재

- 클래스 수와 클래스 간 시각적 유사성 측면에서 난이도가 다른 데이터셋을 이용하여 CNN과 ViT의 표현 능력 차이 비교 가능

- 단순 정확도만의 비교를 넘어 클래스별 성능 분석을 통해 모델별 클래스 단위 성능 특성 비교 분석

Datasets

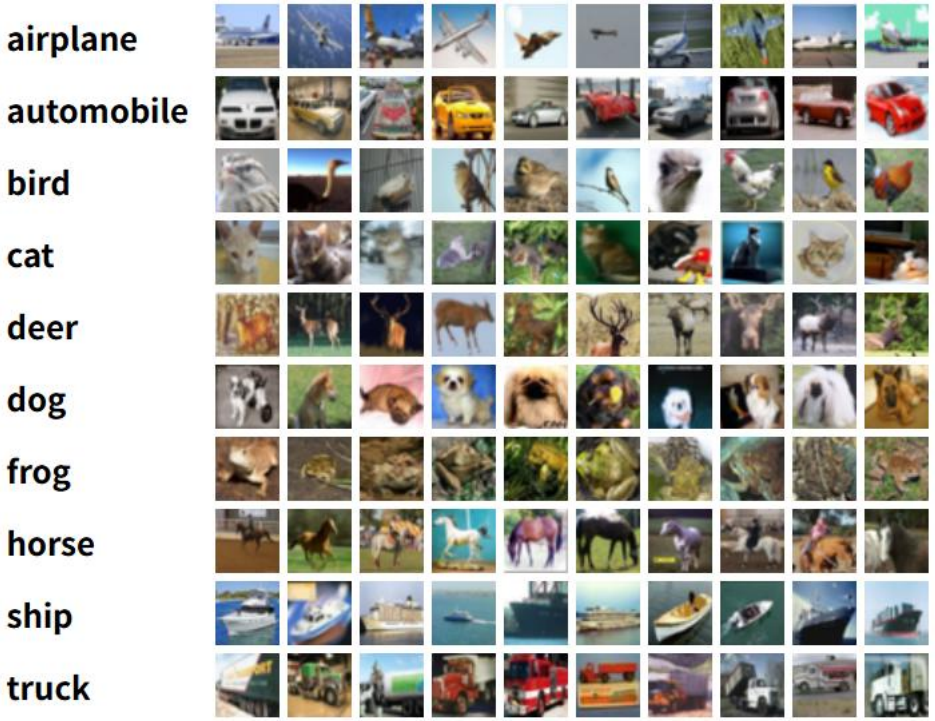

- CIFAR-10 : 32 x 32 크기의 컬러 이미지로 구성, 총 10개의 클래스로 구성된 데이터셋
  - 각 클래스는 6,000장, 학습 데이터 50,000장, 테스트 데이터 10,000장의 이미지
  - 클래스 수가 적고 시각적 복잡도가 상대적으로 낮음

- CIFAR-100 : CIFAR-10과 동일한 해상도를 가지고 총 100개의 클래스로 구성된 보다 복잡한 데이터셋
  - 각 클래스는 600장의 이미지
  - 클래스 간 시각적 유사도가 높아 분류 난이도가 높음

CNN-based Models

1. ResNet18 (Baseline CNN)
   - 지역적 시각 특징 학습에 강점을 가지며 이미지 분류 분야에서 표준 baseline 모델

2. EfficientNet-B0 (Efficient CNN)
   - 비교적 적은 파라미터 수로도 높은 분류 성능을 달성해 성능 대비 계산 효율이 높은 모델

3. ConvNeXt-Tiny (Modern CNN)
   - Vision Transformer의 설계 요소를 합성곱 신경망 구조에 도입한 최신 CNN 계열 모델

세 CNN 모델은 강한 inductive bias를 기반으로, 데이터가 제한된 환경에서 안정적인 학습 성능 제공

Transformer-based Model

- ViT-B/16 (Transformer 기반 모델)
  - 이미지를 패치 단위로 분할 후, self-attention을 통해 전역적 관계를 직접 학습

- Vision Transformer는 inductive bias를 최소화하고 데이터로부터 전역적 관계를 직접 학습

Experimental Setup

Operations Research and Artificial Intelligence Lab

```
DEVICE = torch.device("cuda" if torch.cuda.is_available() else "cpu")
BATCH_SIZE = 16
EPOCHS = 3
LR = 3e-4
```

```
transform = transforms.Compose([
    transforms.Resize((224, 224)),
    transforms.RandomHorizontalFlip(),
    transforms.ToTensor(),
    transforms.Normalize([0.5] * 3, [0.5] * 3)
])
```

- 모든 모델은 GPU를 사용해 동일한 하드웨어 환경에서 학습
- 배치 크기 16, 에폭 수 3으로 모델 간 학습 비용 통제
- 학습률 3e-4로 공정한 성능 비교
- 최적화 기법 적용 전 기본 설정 상태에서 진행
- 모든 이미지는 224x224 해상도로 리사이즈해 동일한 데이터 증강 및 모든 모델에 동일한 정규화 적용

Training Time Comparison

Operations Research and Artificial Intelligence Lab

훈련 시간은 데이터셋이 아닌 모델 구조에 의해 결정

Dataset Model	CIFAR10	CIFAR100
ResNet18	341.55s	344.79s
EfficientNet-B0	541.05s	544.35s
ConvNeXt-Tiny	1403.74s	1398.28s
ViT-B16	1833.28s	1828.49s

ResNet18 : 약 340s로 가장 빠른 모델
→ 가장 짧은 시간으로 안정적인 성능을 보이는 CNN 모델

EfficientNet-B0 : 약 540s로 ResNet보다 약간 느린 모델
→ 정확도 향상이 뚜렷한 속도 – 성능 균형 모델

ConvNeXt-Tiny : 약 1400s로 CNN 모델 중 가장 느린 모델
→ CNN 구조이지만 Transformer 설계를 도입해 연산량이 매우 큰 모델

ViT-B/16 : 약 1830s로 가장 느린 모델
→ 작은 데이터 셋에서도 가장 긴 학습 시간으로 요구하는 모델

Accuracy Comparison

Operations Research and Artificial Intelligence Lab

CIFAR-10에선 대부분 CNN 모델이 높은 성능을 보였으나, CIFAR-100에서는 클래스 수 증가로 인해 모델 간 성능 차이가 크게 나타남

Dataset Model	CIFAR10	CIFAR100
ResNet18	94.74%	77.81%
EfficientNet-B0	94.30%	79.81%
ConvNeXt-Tiny	86.41%	47.29%
ViT-B16	89.38%	75.84%

- CIFAR-10
  - ResNet18, EfficientNet-B0 : 약 94%로 가장 높은 성능, 클래스 수가 적고 지역적 특징이 충분한 데이터셋으로 CNN의 inductive bias가 잘 작동
  - ViT-B/16 : 약 89%로 CNN보다 약간 낮은 성능, ViT는 대규모 데이터셋에 강점이 있지만 CIFAR-10은 상대적으로 데이터가 작아 장점이 충분히 발휘되지 않음
  - ConvNeXt-Tiny : 약 86%로 가장 낮은 성능, CNN이지만 모델이 CIFAR에 비해 과도하게 크고 복잡해 수렴이 충분하지 않음

CIFAR-10에서 CNN의 inductive bias가 효과적으로 작동

Accuracy Comparison

Operations Research and Artificial Intelligence Lab

CIFAR-10에선 대부분 CNN 모델이 높은 성능을 보였으나, CIFAR-100에서는 클래스 수 증가로 인해 모델 간 성능 차이가 크게 나타남

Dataset Model	CIFAR10	CIFAR100
ResNet18	94.74%	77.81%
EfficientNet-B0	94.30%	79.81%
ConvNeXt-Tiny	86.41%	47.29%
ViT-B16	89.38%	75.84%

- CIFAR-100
  - EfficientNet-B0 : 약 80%로 가장 높은 성능, 깊이 / 너비 / 해상도를 균형 있게 조정하는 Compound Scaling을 사용해 클래스 수 증가에도 가장 안정적인 성능
  - ResNet18 : 약 78%로 CIFAR-10 대비 약 17% 하락, 깊이가 상대적으로 얕아 세밀한 구분에 한계
  - ViT-B/16 : 약 76%로 ResNet18보다 약간 낮은 성능, self-attention은 클래스 수 증가 상황에서 전역적 관계를 일부 포착하지만 CIFAR 규모에서는 여전히 데이터가 부족하다는 문제 발생
  - ConvNeXt-Tiny : 약 47%로 가장 낮은 성능으로 학습 실패에 가까움, 데이터 규모에 비해 과도한 모델로 성능이 붕괴됨

클래스 수 증가에 따라 모델 구조에 따른 성능 차이가 크게 확대

Confusion Matrix Analysis on CIFAR-10

Operations Research and Artificial Intelligence Lab

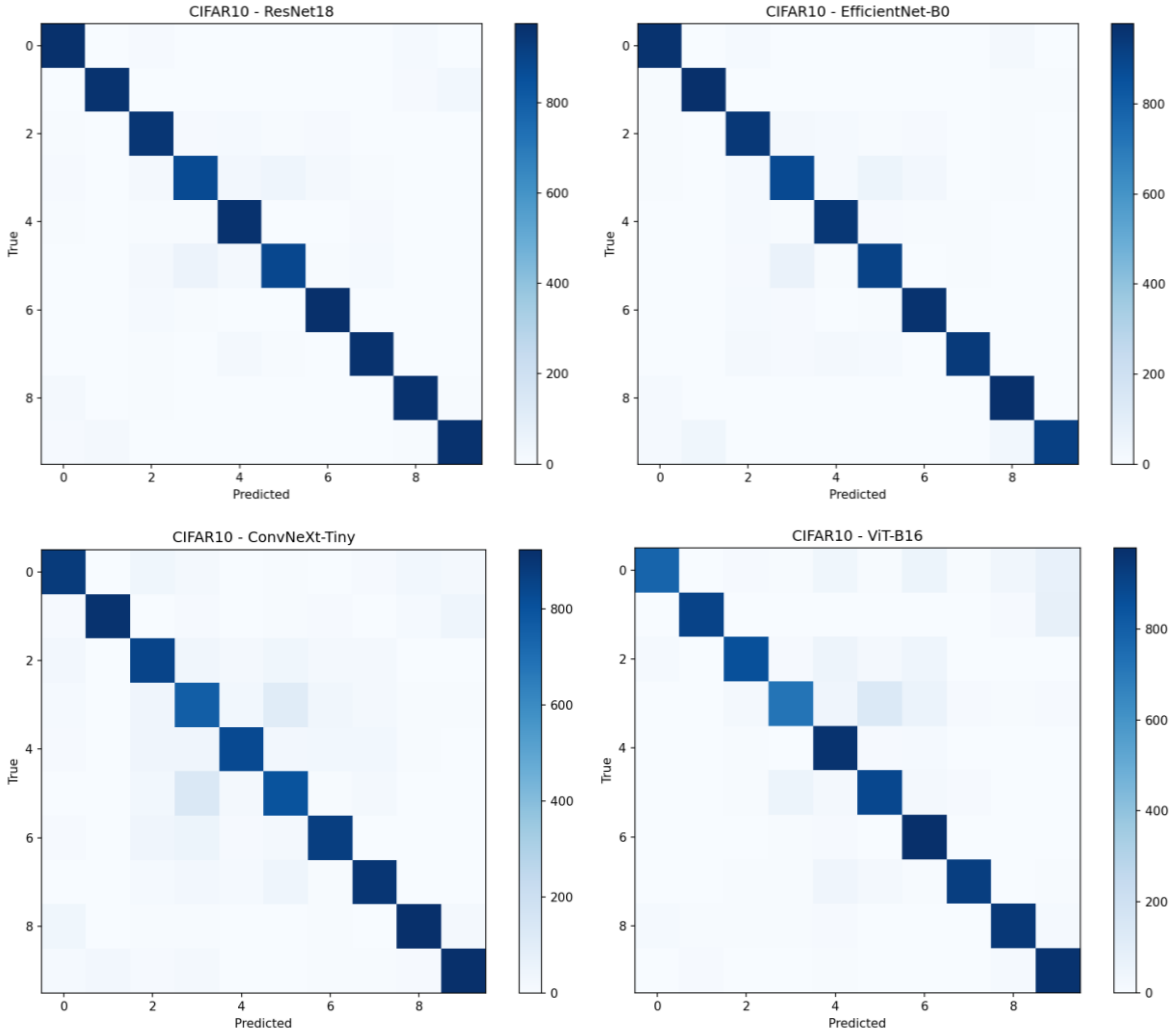

- ResNet18 : 전체적인 정확도는 매우 안정적이지만 3. 고양이와 5. 개 사이의 상호 혼동 발생
- EfficientNet-B0 : 대각선이 매우 뚜렷하며 그 외의 영역이 아주 적음, ResNet18과 마찬가지로 3, 고양이와 5. 개 칼럼 쪽이 상대적으로 진함
- ConvNeXt-Tiny : 대각선이 진하지만, 특정 오답 칸도 진한 특징, ResNet18, EfficientNet-B0과 같은 CNN 모델들 처럼 3. 고양이와 5. 개의 혼동이 존재
- ViT-B/16 : 다른 모델들에 비해 대각선 이외의 칸들에 옅은 파란색이 다수 존재, Vision Transformer가 CNN의 주요 특징인 inductive bias가 적어 해상도가 낮은 이미지에서 세부적인 텍스처를 구분하기 어려움

Class-wise Performance Analysis on CIFAR-10 (F1-score)

Operations Research and Artificial Intelligence Lab

=== 모델별 가장 높은 성능(Best 3) 클래스 ===

	Model	Class	F1-score	Precision	Recall
29	ConvNeXt-Tiny	truck	0.9198	0.9166	0.923
28	ConvNeXt-Tiny	ship	0.9299	0.9379	0.922
21	ConvNeXt-Tiny	automobile	0.9366	0.9660	0.909
16	EfficientNet-B0	frog	0.9593	0.9527	0.966
17	EfficientNet-B0	horse	0.9596	0.9822	0.938
11	EfficientNet-B0	automobile	0.9683	0.9579	0.979
7	ResNet18	horse	0.9650	0.9659	0.964
1	ResNet18	automobile	0.9697	0.9796	0.960
6	ResNet18	frog	0.9701	0.9653	0.975
31	ViT-B16	automobile	0.9403	0.9784	0.905
38	ViT-B16	ship	0.9432	0.9404	0.946
37	ViT-B16	horse	0.9447	0.9675	0.923

모델들 모두 전체적으로 automobile 클래스 분류에는 성능이 높음

ViT-B/16과 ConvNeXt-Tiny는 전역적 정보를 활용한다는 특징으로 automobile과 ship 클래스가 겹침

ResNet18과 EfficientNet-B0는 이미지의 국소적 형태 및 윤곽을 잘 포착한다는 특징으로 automobile, horse, frog 클래스가 겹침

Class-wise Performance Analysis on CIFAR-10 (F1-score)

=== 모델별 가장 낮은 성능(Worst 3) 클래스 ===

	Model	Class	F1-score	Precision	Recall
23	ConvNeXt-Tiny	cat	0.7301	0.7024	0.760
25	ConvNeXt-Tiny	dog	0.7826	0.7668	0.799
22	ConvNeXt-Tiny	bird	0.8249	0.8030	0.848
13	EfficientNet-B0	cat	0.8851	0.8882	0.882
15	EfficientNet-B0	dog	0.9113	0.9136	0.909
12	EfficientNet-B0	bird	0.9339	0.9220	0.946
3	ResNet18	cat	0.8940	0.9161	0.873
5	ResNet18	dog	0.9085	0.9345	0.884
2	ResNet18	bird	0.9356	0.9198	0.952
33	ViT-B16	cat	0.7991	0.8947	0.722
35	ViT-B16	dog	0.8555	0.8227	0.891
30	ViT-B16	airplane	0.8620	0.9618	0.781

CNN과 ViT 모델들 모두 공통적으로 cat과 dog 클래스 분류의 성능이 가장 떨어짐

ResNet18, EfficientNet-B0, ConvNeXt-Tiny 모두 bird 클래스 분류의 성능이 떨어지는데 bird의 특징인 크기가 작고 배경 의존적인 객체에서 분류 성능 저하

ViT-B/16 모델만 airplane 클래스 분류 성능이 떨어지는데 airplane 클래스의 이미지는 대부분 하늘 배경으로 전역적 패치 관계를 학습하는 ViT의 특징에 의해 배경 정보에 과도하게 의존해 성능 저하

Class-wise Performance Analysis on CIFAR-100 (F1-score)

=== CIFAR-100: 모델별 최고 성능(Best 3) 클래스 ===

	Model	Class	F1-score	Precision	Recall
316	ConvNeXt-Tiny	skyscraper	0.7892	0.8588	0.73
322	ConvNeXt-Tiny	sunflower	0.7957	0.8605	0.74
308	ConvNeXt-Tiny	road	0.8187	0.8495	0.79
181	EfficientNet-B0	lawn_mower	0.9490	0.9688	0.93
188	EfficientNet-B0	motorcycle	0.9543	0.9691	0.94
222	EfficientNet-B0	sunflower	0.9645	0.9794	0.95
122	ResNet18	sunflower	0.9208	0.9118	0.93
129	ResNet18	tractor	0.9208	0.9118	0.93
98	ResNet18	pickup_truck	0.9268	0.9048	0.95
422	ViT-B16	sunflower	0.9231	0.9474	0.90
381	ViT-B16	lawn_mower	0.9271	0.9674	0.89
415	ViT-B16	skunk	0.9307	0.9216	0.94

ResNet18 : 전통적인 CNN 특성을 그대로 활용한 구조가 단순하고 시각적 패턴이 명확한 객체에서 높은 성능 보임, Precision과 Recall이 거의 동일해 학습이 안정적

EfficientNet-B0 : 다양한 클래스에서 높은 Precision과 Recall을 동시에 유지, CIFAR-100에서 가장 안정적인 성능

ConvNeXt-Tiny : 배경 구조가 반복되는 장면 기반 클래스에서 비교적 안정적인 성능, Precision이 Recall보다 높아 일부 샘플을 놓치는 경향

ViT-B/16 : 객체의 전체 형태와 색상 분포가 뚜렷한 클래스에서 강점, 전역 특징 포착의 장점인 Recall이 상대적으로 높은 클래스 존재

Class-wise Performance Analysis on CIFAR-100 (F1-score)

=== CIFAR-100: 모델별 최저 성능(Worst 3) 클래스 ===

	Model	Class	F1-score	Precision	Recall
320	ConvNeXt-Tiny	squirrel	0.0672	0.2105	0.04
312	ConvNeXt-Tiny	seal	0.0741	0.1429	0.05
295	ConvNeXt-Tiny	otter	0.1722	0.1651	0.18
151	EfficientNet-B0	boy	0.5244	0.6719	0.43
175	EfficientNet-B0	girl	0.5422	0.4880	0.61
195	EfficientNet-B0	otter	0.5726	0.4797	0.71
75	ResNet18	girl	0.4872	0.6786	0.38
95	ResNet18	otter	0.4949	0.5000	0.49
112	ResNet18	seal	0.5377	0.5089	0.57
436	ViT-B16	willow_tree	0.4559	0.8611	0.31
392	ViT-B16	oak_tree	0.4940	0.6212	0.41
412	ViT-B16	seal	0.4964	0.3908	0.68

ResNet18 : Recall과 Precision이 어느 정도 균형을 맞춤, 얕은 네트워크로 인한 클래스 간 차이가 매우 미세한 fine-grained 분류에 한계 존재, 유사한 질감과 형태를 공유하는 클래스에서 세밀한 구분에 어려움 존재

EfficientNet-B0 : ResNet18과 비슷한 어려움, F1-score가 0.5 이상으로 완전 실패는 아님, boy / girl과 같은 시각적 차이가 미세한 경우에서도 비교적 안정적인 성능을 유지

ConvNeXt-Tiny : 가장 낮은 성능을 보이는 모델, Recall이 극단적으로 낮고 Precision이 상대적으로 높아 확신이 있을 때만 예측, 유사한 외형을 가진 소형 동물 클래스에서 객체를 거의 검출하지 못하는 경향

ViT-B/16 : 다른 모델들과 달리 willow_tree, oak_tree과 같은 나무 클래스가 등장해 배경 중심으로 분류, Precision은 높지만 Recall이 낮아 조심스럽게 예측하는 모델, 배경이 복잡하거나 클래스 간 경계가 모호한 장면 기반 객체에서 재현율 저하

Performance Improvement Strategies

- Batch size를 16에서 32로 증가시켜 gradient 안정성 향상
- Epoch 수를 3에서 5로 증가시켜 충분한 수렴 유도
- ImageNet mean/std 정규화를 적용해 사전학습 가중치와 정합성 확보
  - ImageNet으로 사전학습된 모델의 입력 분포와 일치시켜 학습 성능 향상
- AMP(Automatic Mixed Precision)를 적용해 학습 속도 및 메모리 효율 개선
  - 정밀도가 덜 필요한 계산은 가볍게, 중요한 계산은 무겁게 섞어 속도는 높이고 메모리는 아끼는 AMP를 이용해 학습 효율 개선

Performance Improvement Results – Training Time

Operations Research and Artificial Intelligence Lab

모든 모델, 데이터셋에서 학습 시간 단축

Dataset	Version / Model	Baseline	Optimized	Time_Saved(s)	Speed_Up_X
CIFAR10	ResNet18	341.55	278.84	62.71	1.224896
	EfficientNet-B0	541.05	516.89	24.16	1.046741
	ConvNeXt-Tiny	1403.74	865.06	538.68	1.622708
	ViT-B16	1833.28	1415.18	418.10	1.295439
CIFAR100	ResNet18	344.79	281.71	63.08	1.223918
	EfficientNet-B0	544.35	536.84	7.51	1.013989
	ConvNeXt-Tiny	1398.28	861.43	536.85	1.623208
	ViT-B16	1828.49	1418.37	410.12	1.289149

ResNet18 : 절대적인 시간 약 63초 감소, 안정적이지만 개선 여지는 제한적

EfficientNet-B0 : 절대적인 시간 약 7~24초로 매우 작게 감소, 이미 연산 효율이 높아 추가 최적화 효과 제한적

ConvNeXt-Tiny : 절대적인 시간 약 537초 감소, Baseline 대비 Optimized 시간 약 40% 감소, 연산량과 메모리 사용량이 커 AMP의 이점이 가장 크게 적용

ViT-B/16 : 절대적인 시간 약 410초 감소, ConvNeXt보다는 덜하지만 의미 있는 가속

AMP 적용으로 GPU 연산 효율이 향상되었으며, 그 효과는 모델의 구조에 따라 다르게 나타남

Performance Improvement Results - Accuracy

Operations Research and Artificial Intelligence Lab

모든 모델 및 데이터셋에서 정확도 향상
대형 모델과 난이도 높은 CIFAR-100에서 개선 폭이 매우 큼

Dataset	Version / Model	Baseline	Optimized	Improvement
CIFAR10	ResNet18	94.74%	95.87%	1.13%
	EfficientNet-B0	94.30%	97.29%	2.99%
	ConvNeXt-Tiny	86.41%	94.13%	7.72%
	ViT-B16	89.38%	97.47%	8.09%
CIFAR100	ResNet18	77.81%	80.96%	3.15%
	EfficientNet-B0	79.81%	86.16%	6.35%
	ConvNeXt-Tiny	47.29%	68.86%	21.57%
	ViT-B16	75.84%	89.16%	13.32%

ResNet18 : 기본 학습 안정성이 높아 추가적인 최적화 효과가 제한적

EfficientNet-B0 : 구조적으로 효율적, 학습 환경에 민감하며, 적절한 설정에서 성능 향상이 뚜렷하게 나타남

ConvNeXt-Tiny : CIFAR-10에서 7.79%, CIFAR-100에서 21.57%로 가장 크게 성능 향상, 최적화 이후에야 모델의 표현력 제대로 활용됨

ViT-B/16 : CIFAR-10에서 8.09%, CIFAR-100에서 13.32%로 성능 향상, 학습 조건에 따라 성능 변동 폭이 크고, 최적화 환경에서 특히 큰 성능 향상

ConvNeXt-Tiny, ViT-B/16 모델에서 큰 성능 향상 발생

Worst-class Improvement on CIFAR-10

Operations Research and Artificial Intelligence Lab

=== CIFAR-10: Worst 2 Classes Performance Comparison ===

Model	Version / Class	Baseline	Optimized	Improvement
ResNet18	cat	0.8940	0.9134	0.0194
	dog	0.9085	0.9257	0.0172
EfficientNet-B0	cat	0.8851	0.9375	0.0524
	dog	0.9113	0.9502	0.0389
ConvNeXt-Tiny	cat	0.7301	0.8664	0.1363
	dog	0.7826	0.8975	0.1149
ViT-B16	cat	0.7991	0.9408	0.1417
	dog	0.8555	0.9498	0.0943

ResNet18 : 개선 폭이 1.7~ 1.9%로 가장 작음, 이미 높은 baseline f1-score로 안정적인 모델로 개선 여지가 작음

EfficientNet-B0 : 개선 폭이 3.9 ~ 5.2 %로 상대적으로 작음, normalization & batch size 증가 효과가 반영되어 클래스 간 구분이 애매한 경우에도 균형 잡힌 개선

ConvNeXt- Tiny & ViT-B/16 : baseline에서는 cat/dog 클래스 구분에 실패했지만 최적화 후 대폭 개선, 대형 모델은 기본 설정에서 충분히 학습하지 못했으며, 학습 안정성 개선이 worst-class 분류의 성능에 직접적으로 기여

CIFAR-10에서 최적화 이후 모든 모델에서 worst-class 성능이 개선되었으며, 특히 ConvNeXt와 ViT에서 개선 폭이 큼

Worst-class Improvement on CIFAR-100

Operations Research and Artificial Intelligence Lab

=== CIFAR-100: Worst 2 Classes Performance Comparison ===

Model	Version / Class	Baseline	Optimized	Improvement
ResNet18	girl	0.4872	0.5304	0.0432
	otter	0.4949	0.5514	0.0565
EfficientNet-B0	boy	0.5244	0.6256	0.1012
	girl	0.5422	0.6486	0.1064
ConvNeXt-Tiny	seal	0.0741	0.3544	0.2803
	squirrel	0.0672	0.5475	0.4803
ViT-B16	oak_tree	0.4940	0.7097	0.2157
	willow_tree	0.4559	0.7822	0.3263

ResNet18 : 개선 폭 4.3 ~ 5.7%로 소폭 개선, 단순 구조인 CNN은 미세 클래스 구분에서 개선 폭 제한적

EfficientNet-B0 : 개선 폭 10.1 ~ 10.6%, 사람 클래스에서 의미 있는 상향으로 시각적 패턴이 유사한 클래스에서 안정적인 성능 개선

ConvNeXt-Tiny : 개선 폭 28 ~ 48%로 가장 크게 개선, 최적화 이전에 일부 클래스에서 학습이 거의 이루어지지 않았으나, 최적화 이후 worst-class 성능이 크게 회복

ViT-B/16 : 개선 폭 21.6 ~ 32.6%로 상대적으로 크게 개선, Precision이 높고 Recall이 낮았던 구조에서 Optimized 후 Recall 회복으로 f1-score 상승, 전역적 패턴 학습에 유리해 배경 중심 클래스에서 최적화 효과 크게 나타남

CIFAR-100에서 최적화가 worst-class 성능에 결정적인 영향을 미쳤으며, ConvNeXt와 ViT는 기존에 분류가 거의 불가능했던 클래스에서도 유의미한 성능 회복

Conclusion

- CNN 기반 모델과 Vision Transformer를 CIFAR-10과 CIFAR-100 데이터셋에서 비교 분석 진행
- CNN 모델은 CIFAR-10과 같은 비교적 단순한 데이터셋에서 안정적인 성능을 보였으며, Vision Transformer는 CIFAR-100과 같은 fine-grained 분류 환경에서 더 높은 성능 달성
- 학습 설정 최적화를 통해 모든 모델에서 학습 시간 단축과 정확도 향상을 동시에 달성
- 데이터셋 특성과 모델 구조에 따라 적절한 모델 선택이 중요함을 확인

Q & A