Object Detection

산업경영공학과 12210588 고우현

인하대학교
INHA UNIVERSITY

Operations Research and
Artificial Intelligence Lab

Contents

Operations Research and Artificial Intelligence Lab

- Object Detection
- Two-Stage Object Detection Model
- One-Stage Object Detection Model
- Object Detection Model based on Transformer
- Applications of Object Detection

Object Detection

Classification

CAT

Object Detection

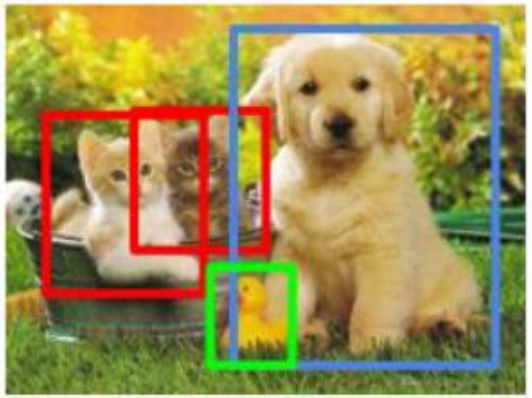

CAT, DOG, DUCK

Object Detection : Computer Vision 분야에서 이미지나 비디오에서 객체를 탐지하고, 해당 객체의 위치와 크기를 식별하는 기술

Classification & Localization

Object Detection은 객체 분류(classification)와 객체 위치 식별(localization)로 분류

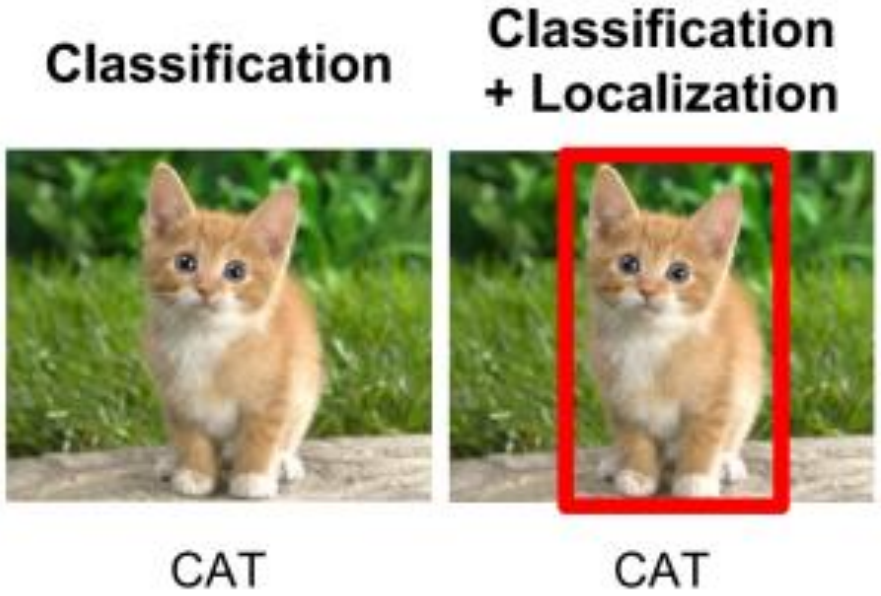

- 객체 분류(classification) : 이미지에서 객체가 무엇인지 판단하는 작업
- 객체 위치 식별(localization) : 이미지에서 객체가 어디에 있는지를 찾아내는 작업, 이미지 내에서 각 객체의 경계 상자(bounding box)를 찾는 것
  - 경계 상자(bounding box) : 객체의 위치와 크기를 식별하는 정보를 담고 있으며 일반적으로 사각형 형태로 표현

Object Detection model은 이미지 내에 여러 객체를 동시에 감지하고, 각 객체의 클래스와 경계 상자를 출력

Intersection over Union(IoU)

Operations Research and Artificial Intelligence Lab

객체 탐지(object detection)에서 사용되는 평가 지표 중 하나로 객체의 경계 상자가 얼마나 정확한지를 측정하는데 사용

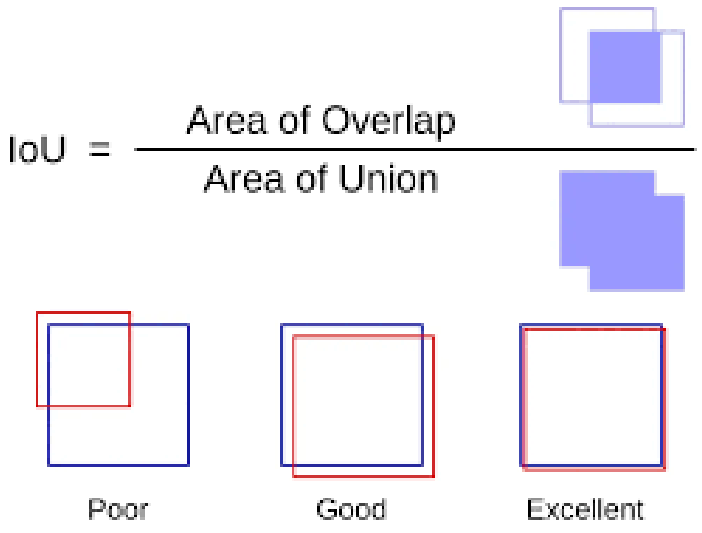

IoU = Area of Overlap / Area of Union

Area of Overlap : 두 경계 상자가 겹치는 영역의 면적

Area of Union : 두 경계 상자의 결합 영역의 면적

IoU의 값은 0과 1 사이의 값이며, 1에 가까울수록 경계 상자가 정확

객체 탐지 모델에서 IoU를 사용해 모델이 예측한 경계 상자와 실제 레이블의 경계 상자가 얼마나 일치하는지를 측정

IoU 값이 임계값(threshold)보다 크면 예측이 올바른 것으로 판단

mean Average Precision(mAP)

Operations Research and Artificial Intelligence Lab

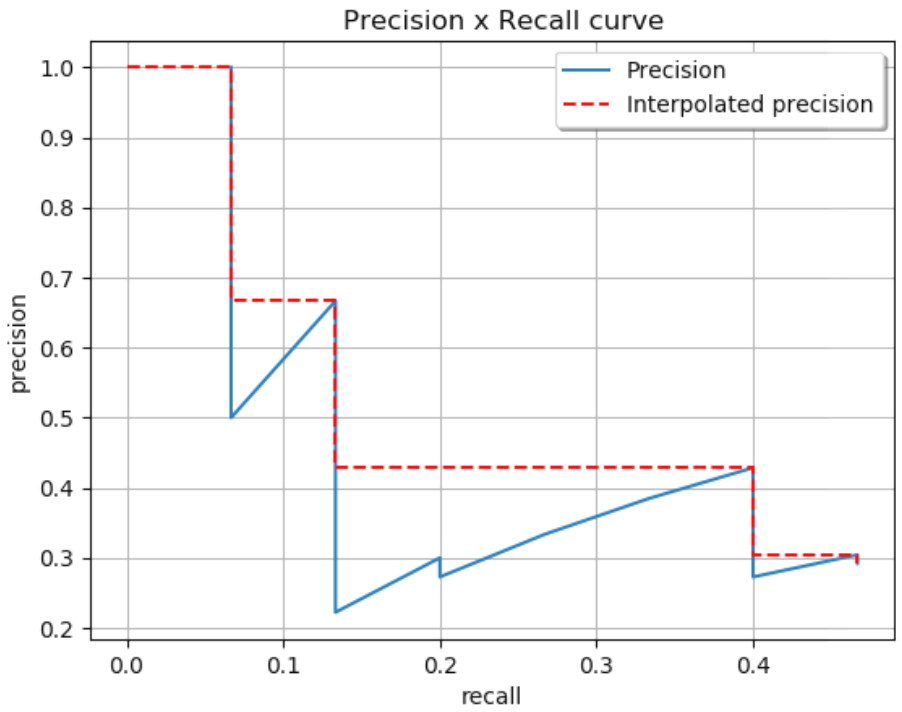

Average Precision(AP) : 재현율(Recall) 값에 따른 정밀도(Precision) 값들의 평균으로 개별 class에 대해 평균적으로 얼마나 높은 예측 정확도를 갖는지 평가하는 지표

Mean Average Precision(mAP) : 모든 class에 대해 계산하여 평균 낸 지표

객체 탐지 모델은 IoU를 기준으로 예측의 정답 여부를 판단하고, mAP를 통해 최종 성능을 평가

Two-Stage Object Detection Model

2-Stage Detector - Regional Proposal와 Classification이 순차적으로 이루어짐.

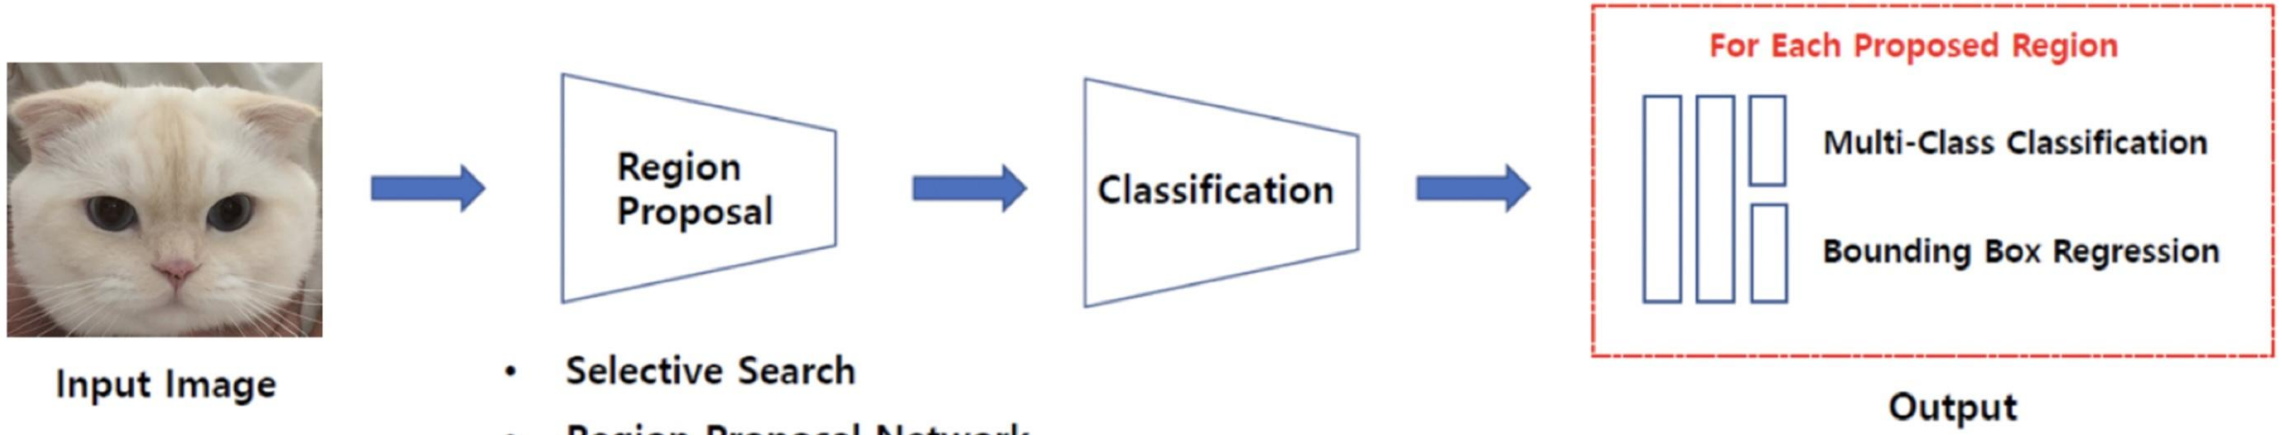

- Selective Search
- Region Proposal Network
- etc.

Ex) **R-CNN 계열** (R-CNN, Fast R-CNN, Faster R-CNN, R-FCN, Mask R-CNN ...)

두 단계(Stage)로 구성된 접근 방식

첫 번째 단계에서 입력 이미지의 주요한 객체(proposal) 후보를 선택하고, 두 번째 단계에서 선택된 객체 후보들에 대해 객체 위치와 클래스를 정확하게 예측

높은 정확도와 안정성을 가지지만, 상대적으로 느린 속도와 높은 컴퓨팅 자원 필요

Two-Stage Object Detection Model

- Key model
  - R-CNN : Selective Search로 region proposal 생성하고 CNN에 개별 입력, 매우 느리다는 단점
  - Fast R-CNN : 전체 이미지에서 feature map을 1번만 추출해 속도 대폭 향상, proposal은 여전히 외부 알고리즘을 사용한다는 단점
  - Faster R-CNN : 입력 이미지의 feature map에서 객체가 있을 법한 후보 영역을 생성하는 신경망인 RPN을 도입해 proposal까지 CNN이 학습, Two-stage 모델의 표준

- Recent model
  - Mask R-CNN : Faster R-CNN 구조를 기반으로 각 객체에 대해 bounding box와 class뿐만 아니라 픽셀 단위의 instance segmentation mask를 예측하도록 확장한 모델, 픽셀 수준으로 세분화 가능
  - Cascade R-CNN : Faster R-CNN을 기반으로, 점점 더 높은 IoU 기준을 갖는 여러 개의 detection head를 단계적으로 연결해 bounding box를 점진적으로 정밀화하는 모델, 높은 IoU 조건에서도 강한 모델

One-Stage Object Detection Model

1-Stage Detector - Regional Proposal와 Classification이 동시에 이루어짐.

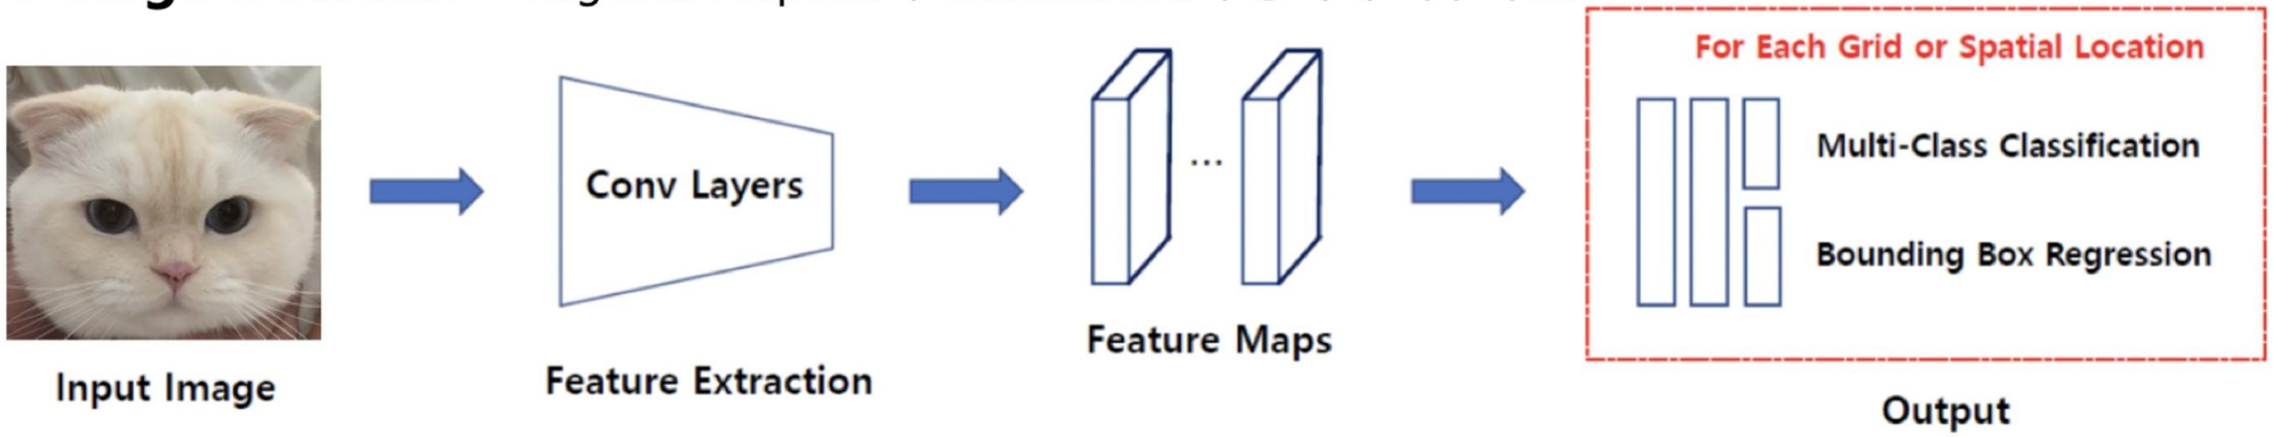

Ex) **YOLO 계열** (YOLO v1, v2, v3) , **SSD 계열** (SSD, DSSD, DSOD, RetinaNet, RefineDet ...)

단일 단계(Single Stage)로 구성된 접근 방식

입력 이미지에서 바로 객체의 위치와 클래스를 예측하는 방식

빠른 속도와 낮은 컴퓨팅 자원을 필요로 하지만, 상대적으로 낮은 정확도와 불안정성을 가질 가능성 존재

One-Stage Object Detection Model

- Key model
  - YOLO : 이미지를 grid로 나누고 각 grid cell에서 경계 상자, 클래스 확률, confidence score를 동시에 예측, End-to-end 학습이 가능하지만 작은 객체, 밀집 객체에 약함
  - SSD : Multi-scale feature maps를 사용해 서로 다른 해상도에서 anchor box를 예측, 다양한 크기의 객체에 대응하고 작은 객체 성능을 개선하지만, anchor 설계가 필요하고 클래스간의 불균형 문제가 존재
  - RetinaNet : 극단적 클래스 불균형 문제를 해결해 One-stage도 Two-stage 수준의 정확도가 가능함을 증명
  - FCOS (Anchor-Free) : 객체를 center point 기준으로 예측해 구조가 단순하고 hyperparameter를 감소한다는 장점
  - CenterNet : 객체를 keypoint(중심점) 탐지 문제로 변환

- Recent model
  - YOLOv7 : YOLO 계열 중 가장 이론적으로 정리된 모델로 학습, 추론 최적화에 집중해 속도와 정확도를 동시에 개선
  - YOLOv8 : Anchor 설계를 제거해 일반화 향상하고 classification과 localization 간 간섭 감소
  - YOLOv9 : 깊은 one-stage 모델에서 정보 손실 문제 해결해 학습 안정성을 향상
  - YOLOX : Anchor-free YOLO의 본격적인 도입, YOLO 계열 anchor-free 전환의 출발점

Limitations of Conventional Object Detection Models

- Anchor Box 설계 : 수동 튜닝이 필요
  - 기존에는 객체 인식을 위해 이미지 내의 모든 가능한 위치와 다양한 크기의 윈도우를 슬라이딩 하며 객체의 존재 여부를 확인
  - 높은 계산 비용, 다양한 종과 횡 비, 객체 크기의 변화 등의 문제가 있어 미리 다양한 형태의 박스를 정의해서 효율적으로 계산하게 하는 Anchor Box 사용
  - Anchor의 크기, 비율, 수량 등을 수동 설계 및 튜닝해야 하고, 데이터셋마다 최적 Anchor 구성이 달라 범용성이 떨어지고, Anchor Box가 실제 객체와 맞지 않으면 탐지 성능이 저하된다는 문제점 발생

- Non-Maximum Suppression (NMS) : 복잡한 후처리
  - 기존 모델들은 같은 객체에 대해 여러 개의 박스를 예측하게 되는데 이를 해결하기 위해 겹치는 박스 중 가장 신뢰도가 높은 것만 남기고 나머지를 제거하는 NMS 알고리즘을 사용
  - NMS는 임계값 설정이 민감해 성능에 영향을 주고, 근접한 객체를 잘못 제거할 위험이 있으며 GPU 병렬화에 적합하지 않아 연산 속도에 제약이 있다는 문제 발생

Limitations of Conventional Object Detection Models

- 모듈 분리 구조 : End-to-End 학습이 어려움
  - 기존 모델은 Backbone, Region Proposal Network (RPN), RoI Pooling, Classifier & Box Regressor 의 여러 개의 모듈로 구성됨
  - 각 모듈이 분리된 방식으로 동작해 전체 모델을 하나로 학습하기 어렵고, 학습 파이프라인이 복잡하고, 디버깅이 어려우며 성능 병목이 발생가능하다는 문제 발생

- Region Proposal 필요
  - Faster R-CNN과 같은 모델은 먼저 수천 개의 후보 박스(region proposals)를 생성한 후, 이 중에서 진짜 객체를 분류하는데 이는 RPN을 통해 수행
  - Region Proposal 단계는 추가적인 연산과 학습이 필요하고, 전체 처리 속도를 느리게 만들고 구조 복잡도를 증가시킨다는 문제 발생

→ 위의 한계들을 해결하기 위해 Transformer 기반 Object Detection model 등장

Object Detection Model based on Transformer

DETR (Detection Transformer) : 기존 CNN 기반의 탐지기와 달리 Transformer를 사용한 최초의 객체 탐지 모델

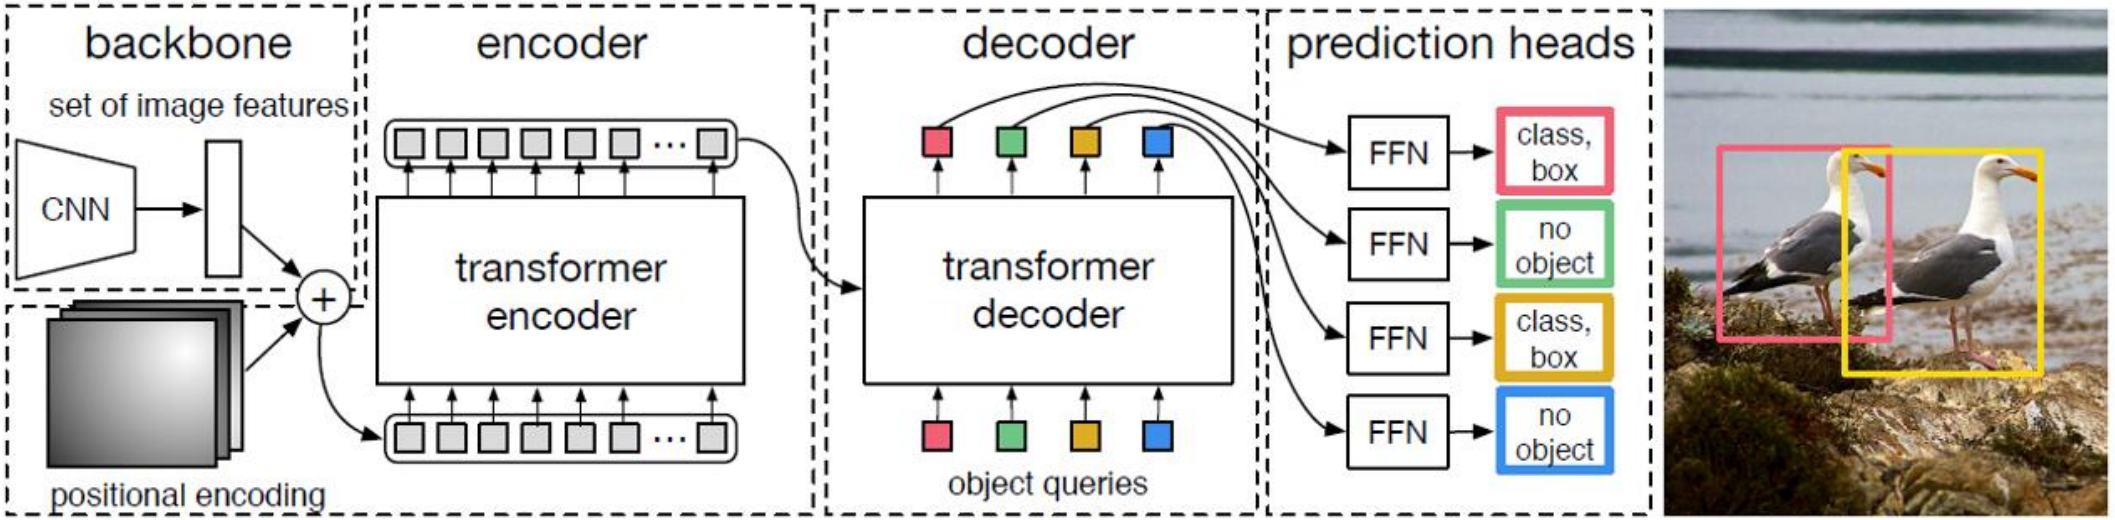

- Backbone : 이미지 특징을 추출
  - 입력 이미지를 처리하기 위해 CNN 기반 backbone 사용 (ResNet-50, ResNet-101)
  - 고수준의 시각 특징(feature map)을 추출하고 이미지의 공간적 정보를 담고 있는 2D feature map을 출력

- Transformer Encoder-Decoder
  - Encoder : CNN의 feature map을 flatten하여 sequence로 변환하고 self-attention 기반 encode에 입력해 이미지의 전역 컨텍스트(global context)를 학습
  - Decoder : 각 query는 예측해야 할 객체 한 개를 담당하는 learnable한 object query 집합을 입력받고 encoder output과 cross-attention을 통해 이미지와 상호작용하여 객체 위치(box)와 클래스(class)를 예측

Object Detection Model based on Transformer

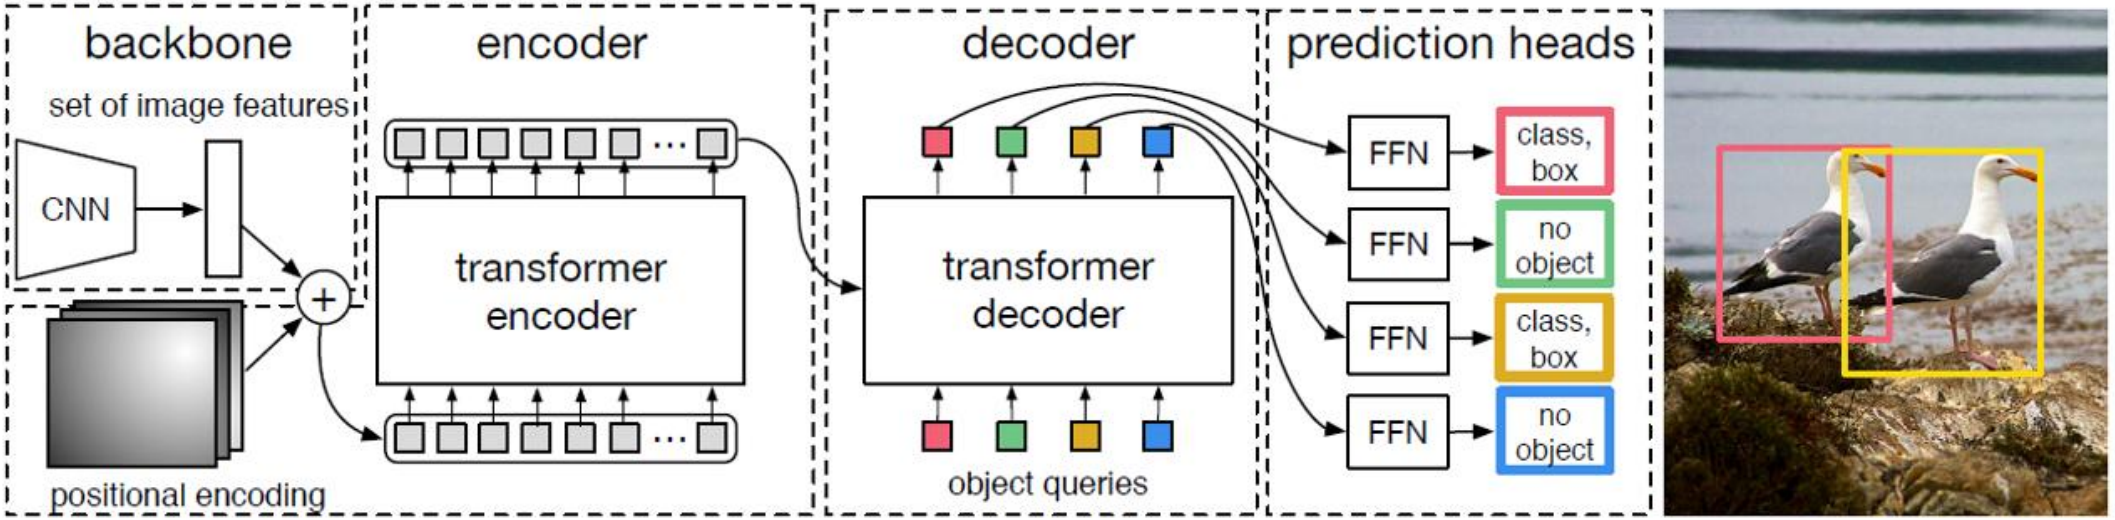

- Prediction Heads
  - Transformer Decoder의 출력은 각 벡터가 하나의 객체를 예측하기 위한 정보를 담은 임베딩 벡터들
  - Class Prediction Head : 각 쿼리에서 예측된 객체의 클래스 정보를 출력
  - Bbox Prediction Head : 각 쿼리에 대해 객체의 Bounding Box 예측
- Object Query
  - 고정된 개수의 learnable object query를 사용
  - 각 query는 하나의 객체를 예측하기 위한 학습 가능한 벡터로 개수가 고정되어 있고, 일부는 실제 객체, 일부는 'no object'로 분류되어 직접적인 위치 학습 가능
- Hungarian Matching : 두 집합 간의 최적의 1:1 매칭을 찾는 할당 문제를 해결하는데 최적화된 알고리즘
  - 모든 GT 객체를 예측 중 가장 잘 맞는 하나의 query와 매칭하는 최적의 조합 계산
  - 이를 통해 NMS 없이도 중복 없이 깔끔한 탐지 결과 제안 가능

Advantages of Object Detection Model based on Transformer

- 완전한 End-to-End 학습 구조
  - 이미지 입력부터 객체 위치(box)와 클래스(class)까지 단 하나의 손실 함수로 직접 학습 가능
  - 별도의 후처리가 필요 없어 결과적으로 코드가 단순해지고, 디버깅과 유지보수가 쉬워짐

- Anchor-Free & NMS-Free
  - Anchor-Free : 사전 정의된 anchor box가 없고 transformer의 object query가 객체 위치를 직접 예측하고 anchor 튜닝 필요 없이 데이터 특성에 자동 적응함
  - NMS-Free : 각 object query가 하나의 객체만 담당하도록 학습되어 NMS가 불필요하고 후처리 없이도 정확한 예측이 가능
  - 학습 및 추론 파이프라인이 더 간단하고 깔끔해짐

- Transformer의 global context 활용
  - 기존 CNN 기반 모델들은 로컬 특징 중심이지만 DETR은 transformer를 사용해 이미지 전체의 패치 간 관계를 학습함
  - 복잡한 배경, 겹친 객체, 구조적 관계 탐지에 유리함

Limitations of Object Detection Model based on Transformer

- 수렴 속도가 매우 느림
  - Object query가 랜덤한 상태로 시작되며, 지도 학습 이전까지 의미 없는 예측이 지속되고 초기에는 학습 신호가 부족함
  - Object query와 ground truth 간의 의미 있는 연결을 찾는데 시간이 오래 걸리고, 기존 모델에 비해 수렴 속도가 현저히 느림
- 작은 객체 탐지 성능 저하
  - Transformer는 global attention 기반으로 작동하지만, 이로 인해 세밀한 국소적 정보가 약해질 수 있음
  - 작은 객체는 feature map에서 잘 표현되지 않아 query가 해당 객체를 잡아내기 어렵고 해상도가 낮아질수록 작은 객체는 더 희미해짐
- Transformer 연산량 문제
  - Transformer 구조는 self-attention 연산으로 진행되어 고해상도 이미지일수록 연산량과 메모리 사용이 급격히 증가함
  - 추론 속도가 느리고, GPU 메모리 사용량이 크며 batch size도 제한적임

Object Detection Model based on Transformer

- Key model
  - DETR : Transformer 기반 객체 탐지의 시작점
    - 객체 탐지를 Set Prediction 문제로 정의해 anchor, NMS를 제거하고 End-to-End 학습을 하는 최초의 transformer 기반 모델
    - 학습 수렴이 느리고 작은 개체의 성능이 저하되며 실시간 적용이 어렵다는 문제점
  - Deformable DETR : DETR의 실질적 한계 해결 모델
    - 소수의 중요한 위치만 선택적으로 attend하는 sparse attention을 통해 학습 속도를 대폭 개선
    - 작은 객체의 성능이 향상되고 Multi-scale feature를 활용해 transformer 기반 탐지가 현실적으로 사용이 가능해짐
- Recent model
  - DINO : 학습 안정성과 성능을 크게 개선한 모델
    - 정답에 일부러 노이즈를 섞은 입력을 주고 모델이 원래의 정답을 복원하도록 학습시키는 방법인 denoising 전략을 통해 object query 학습을 안정화시킨 최신 DETR 계열 모델
    - 빠른 수렴이 가능하고 성능이 향상되며 안정적인 학습이 장점으로 모델의 학습 문제를 정교하게 해결
  - DN-DETR : Denoising 학습을 본격적으로 도입
    - Denoising query를 통해 Hungarian matching의 학습 안정성을 개선
  - RT-DETR : 실시간 Transformer 객체 탐지
    - CNN과 Transformer가 hybrid로 결합한 모델로 One-stage 구조
    - Transformer 기반 객체 탐지를 실시간 환경에서도 가능하게 한 모델

Applications of Object Detection

- 보안 및 안전 관리 : CCTV 영상 분석을 통해 침입자 감지, 작업자의 위험 행동(추락, 안전 장비 미착용), 화재(연기, 불꽃) 등을 실시간으로 탐지
- 제조 및 로봇 공학 : 로봇이 조립할 부품을 인식하거나, 작업자의 안전 구역 이탈을 감지하는데 사용
- 스마트폰 및 가전 : 얼굴 인식 잠금 해제, 사진 앱의 자동 태그 지정(사람, 동물, 사물), 카메라의 자동 초점(AF)
- 농업 : 농작물의 상태를 분석하거나 해충을 탐지하는데 사용

Q & A